PUCPR

PONTIFÍCIA UNIVERSIDADE CATÓLICA DO PARANÁ

DATA ANALYTICS / PROJETO BASEADO EM PROBLEMAS

RA1

Ingestão e preparação dos dados

Documentação da entrega

Projeto Perfil das faixas populares nos charts da Deezer por gênero

Curso e turma Bacharelado em Sistemas de Informação • 2º semestre de 2026

Professor ou professora Marina de Lara

Equipe Eduardo Fabri • João Correa • Rodrigo Alves • João Pedro Cardoso

Repositório https://github.com/eduardofabrii/data-analytics-ras

Entrega Curitiba • 21/10/2026

RA1 / 01

Problema e perguntas analíticas

Defina o contexto do projeto e as perguntas que orientarão a seleção e a preparação dos dados.

Contexto e problema

Os charts da Deezer mostram as faixas mais ouvidas no geral e em cada gênero. Artistas, gravadoras e curadores de playlists os usam para decidir o que lançar e promover, mas o chart traz só a ordem das faixas, não o que elas têm em comum. Este projeto descreve o perfil das faixas do topo de cada gênero: duração, idade do lançamento, popularidade do artista e concentração de poucos artistas no ranking. Saber se esse perfil muda entre gêneros ajuda quem produz e divulga música a comparar a própria faixa com o que se ouve no gênero dela.

Objetivo e recorte

Objetivo: montar um conjunto de dados confiável com as faixas dos charts da Deezer e os atributos da faixa, do álbum e do artista, para comparar o perfil das faixas populares entre gêneros nas etapas seguintes.

Período: um único retrato dos charts, na data da coleta registrada na seção 02 (ficha da fonte). O chart é ao vivo; o projeto não acompanha sua evolução.

Unidade de observação: a faixa (objeto track da API). Uma faixa pode estar em mais de um chart; o gênero de comparação é o do chart em que ela aparece.

População coberta: as primeiras posições do chart geral e dos charts de cada gênero listado pela API (/genre e /chart/{id_genero}/tracks), com o detalhe de cada faixa, álbum e artista.

Limites: só faixas dos charts, não o catálogo inteiro; charts vistos a partir do país da coleta, registrado na seção 02; sem número de reproduções, só o rank, índice de popularidade calculado pela Deezer; atributos de áudio como bpm ficam fora das perguntas, porque a API costuma devolvê-los zerados quando não os calculou.

Perguntas analíticas

ID	Pergunta a investigar	Dados necessários
P1	Como a duração das faixas varia entre os gêneros dos charts da Deezer na data da coleta?	duration (segundos) da faixa; gênero do chart de origem (/genre, /chart/{id_genero}/tracks)
P2	Que parte das faixas de cada chart de gênero foi lançada nos 12 meses anteriores à coleta?	release_date de /track/{id}; gênero do chart de origem; data da coleta
P3	Faixas de artistas com mais fãs têm rank mais alto, no chart geral e dentro de cada gênero, na data da coleta?	rank da faixa; nb_fan de /artist/{id}; gênero do chart de origem
P4	Quantos artistas distintos ocupam as posições de cada chart de gênero e que fatia dessas posições fica com os 5 artistas com mais faixas?	artist.id do item do chart; position; gênero do chart de origem

Viabilidade inicial

Todos os campos das perguntas existem na API pública da Deezer, sem autenticação: duration, rank, position e artist.id em /chart/{id_genero}/tracks, release_date em /track/{id}, nb_fan em /artist/{id} e os gêneros em /genre (fontes 1 e 2). Coletar cada chart de gênero registra o gênero de origem em cada item, sem depender do gênero do álbum.

Lacunas a confirmar na seção 03: a faixa pode estar no chart geral e no do seu gênero, e a deduplicação precisa preservar o gênero de origem; release_date e nb_fan podem vir ausentes ou zerados, reduzindo a base de P2 e P3; o gênero do chart, da Deezer, pode diferir do gênero do álbum; e um único retrato não mostra tendência.

RA1 / 02

Fontes de dados e ingestão

Documente a origem dos dados e como eles são carregados no ambiente do projeto. Duplique a ficha para cada fonte.

Ficha da fonte

Identificação F1 • Charts de faixas da Deezer (geral e um por gênero), com os detalhes de cada faixa, álbum e artista.

Origem e acesso Deezer • API pública https://api.deezer.com, sem autenticação nem chave (documentação: https://developers.deezer.com/api) • data de acesso: 16/10/2026.

Formato e volume JSON via API REST, gravado como recebido (57,7 MB no retrato de 16/10/2026) • 2.800 itens em 28 charts, com 2.581 faixas, 2.292 álbuns e 1.688 artistas únicos • atributos da faixa (id, title, duration, rank, explicit_lyrics, preview, position, bpm, isrc, release_date), do álbum (genre_id, genres, label, release_date, record_type, nb_tracks) e do artista (name, nb_fan, nb_album); o df_bruto tem 102 colunas.

Cobertura charts do dia da coleta, sem histórico; cada um traz as 100 faixas mais populares no momento da requisição (total = 100 em todos) • país aparente: US (Estados Unidos) • charts: o geral (gênero 0) e os gêneros de /genre.

Condições de uso API pública; os dados pertencem à Deezer e aos detentores de direitos e são usados só para fins acadêmicos, sem redistribuir as prévias de áudio. A coleta respeita o limite de chamadas com pausa entre requisições.

Relação com o problema

Todos os campos das quatro perguntas (seção 01) vieram no retrato de 16/10/2026 e estão no df_bruto, e cada item guarda o chart de gênero de origem:

- **P1** (duração por gênero): duration e o gênero do chart (chart_id_genero, chart_nome_genero).
- **P2** (lançamentos dos 12 meses anteriores à coleta, por gênero): detalhe_faixa_release_date, o gênero do chart e a data da coleta, no metadados.json.
- **P3** (fãs do artista e rank): rank, detalhe_artista_nb_fan e o gênero do chart.
- **P4** (concentração de artistas por chart): artist_id, position e o gênero do chart.

Por ser de um único dia e país aparente (US), a fonte não apoia perguntas sobre evolução no tempo nem comparações entre países.

Procedimento de ingestão

Etapa	Procedimento ou parâmetro	Evidência no repositório
1	Acesso: GET em https://api.deezer.com, pausa de 0,15 s, até 4 tentativas com espera crescente; o objeto error devolvido com HTTP 200 é tratado (código 4, limite de chamadas, ganha nova tentativa; os demais são registrados)	notebook §2, célula "Parâmetros da coleta e acesso à API"

Etapa	Procedimento ou parâmetro	Evidência no repositório
2	Charts: /genre lista os gêneros e /chart/{id}/tracks traz o geral e cada gênero, paginado por index e limit=100, até o fim ou 300 itens; /infos registra o país aparente	notebook §2, célula "Coleta dos charts por gênero"
3	Detalhes: /track/{id}, /album/{id} e /artist/{id} para cada faixa, álbum e artista únicos	notebook §2, célula "Coleta dos detalhes de faixas, álbuns e artistas"
4	Retrato bruto: respostas cruas em dados/brutos/AAAA-MM-DD/ (infos.json, generos.json, charts.json, faixas.json, albuns.json, artistas.json) e metadados.json (início e fim, país, parâmetros, chamadas por endpoint, novas tentativas e erros). As etapas 2 a 4 só rodam com BAIXAR_DA_API = True	notebook §2, célula "Gravação do retrato bruto"; dados/brutos/2026-10-16/
5	Leitura: com BAIXAR_DA_API = False (padrão), lê o retrato mais recente de dados/brutos/ e mostra o metadados.json	notebook §2, células "Leitura do retrato bruto mais recente" e "Metadados do retrato lido"
6	df_bruto: uma linha por item de chart, com a origem (chart_id_genero, chart_nome_genero, chart_ordem) e os campos de faixa, álbum e artista juntados pelo id (prefixos detalhe_faixa_, detalhe_album_, detalhe_artista_), sem limpeza e com as repetições entre charts	notebook §2, célula "Montagem do df_bruto"
7	Verificação: linhas contra os metadados, faixas, álbuns e artistas únicos, itens sem detalhe, colunas por origem e itens por chart	notebook §2, célula "Verificação do carregamento"

Resultado da ingestão

A coleta de 16/10/2026 (21h03 a 21h41 UTC) fez 6.591 chamadas, sem novas tentativas nem erros (dados/brutos/2026-10-16/metadados.json). Os 28 charts (o geral e 27 gêneros) vieram com 100 itens cada, numa página: é o que a API oferece (total = 100), abaixo do teto de 300. O df_bruto tem 2.800 linhas e 102 colunas, com 2.581 faixas, 2.292 álbuns e 1.688 artistas únicos, e nenhum item sem detalhe (notebook §2, célula "Verificação do carregamento"). O retrato fica versionado em dados/brutos/AAAA-MM-DD/ e toda execução lê o mesmo. A única etapa manual é a coleta, feita uma vez no Google Colab ou na máquina de um integrante (a API exige acesso direto à internet), com o retrato enviado ao repositório.

RA1 / 03

Compreensão e qualidade

Descreva o que cada registro representa e apresente evidências das verificações de qualidade relevantes para os dados.

Unidade de observação ocorrência de faixa num chart de origem, no retrato de 16/10/2026: 2.800 ocorrências, 102 atributos, 2.581 faixas, 28 charts (geral e 27 gêneros). Evidência: notebook §3, célula “Visão geral e tipos observados”, sobre dados/brutos/2026-10-16/.

Identificação dos registros id identifica a faixa e se repete entre charts; a chave é o par chart_id_genero e id, com zero excedentes em 2.800 (retratos futuros exigirão a data na chave). A posição pertence ao chart, não à faixa. Evidência: notebook §3, célula “Duplicidade e limite da chave”.

Dicionário inicial dos dados

Atributos usados pelas P1–P4, pelo RA2 e por este diagnóstico; os demais (URLs, capas, países, colaboradores) ficam no bruto. Os 102 atributos e suas ausências estão nas células “Visão geral e tipos observados” e “Ausências nulas e textos vazios”. Tipos do pandas 2.3.3; textos são object, sem conversão de data.

Atributo	Significado	Tipo e formato	Unidade ou domínio
chart_id_genero	Id do chart de origem; grupo das P1–P4	int64	Inteiro ≥ 0; 0 = geral
chart_nome_genero	Nome do chart; grupo das P1–P4 e gênero do evento RA2	object	Texto; All = geral
chart_ordem	Ordem da ingestão; verifica a posição (P4)	int64	Inteiro positivo, por chart
id	Id da faixa nas P1–P4; origem de id_faixa no RA2	int64	Inteiro positivo; repete entre charts
title	Título; identificação nas P1–P4	object	Texto
title_version	Versão; ausência informativa	object	Texto ou nulo; vazio permitido
duration	Duração (P1); limite da duração ouvida no RA2	int64	Segundos, inteiro positivo
rank	Popularidade (P3); peso do sorteio no RA2	int64	Inteiro ≥ 0; não é a posição
position	Posição no chart (P4)	int64	Inteiro positivo
explicit_lyrics	Conteúdo explícito; verificação de tipo	bool	Booleano
preview	URL da prévia; ausência, sem uso nas P1–P4	object	Texto, pode ser vazio

Atributo	Significado	Tipo e formato	Unidade ou domínio
artist_id	Id do artista (P3 e contagem da P4)	int64	Inteiro positivo
artist_name	Nome do artista (P3–P4, evento RA2)	object	Texto; agrupar pelo id
album_id	Id do álbum; chave do enriquecimento	int64	Inteiro positivo
detalhe_faixa_id	Id de /track; integridade da junção	int64	Domínio de id
detalhe_faixa_duration	Duração em /track; consistência com duration	int64	Segundos, inteiro positivo
detalhe_faixa_rank	Rank em /track; consistência com rank	int64	Inteiro ≥ 0
detalhe_faixa_release_date	Lançamento da faixa (P2), não do álbum	object	AAAA-MM-DD; até a coleta
detalhe_faixa_bpm	Andamento; diagnóstico, sem uso nas P1–P4	float64	BPM, real; zero a avaliar
detalhe_faixa_gain	Ganho; diagnóstico, sem uso nas P1–P4	float64	dB, real; negativo válido, zero a avaliar
detalhe_album_id	Id de /album; integridade da junção	int64	Domínio de album_id
detalhe_album_genre_id	Gênero do álbum; não é o grupo das P1–P4	int64	Inteiro; ≤ 0 é genérico
detalhe_album_release_date	Lançamento do álbum; formato, não substitui a data da P2	object	AAAA-MM-DD; até a coleta
detalhe_artista_id	Id de /artist; integridade da junção	int64	Domínio de artist_id
detalhe_artista_nb_fan	Fãs do artista (P3)	int64	Inteiro ≥ 0

Diagnóstico de qualidade

Denominador: **2.800 ocorrências**; as verificações não se somam e repetições contam só os excedentes.

Q1 cobre id, chart_id_genero, chart_nome_genero, title, duration, rank, position, artist_id, artist_name, album_id, detalhe_faixa_release_date e detalhe_artista_nb_fan. Q7 espera inteiros nas chaves e contagens, reais em BPM e gain e booleano em explicit_lyrics. Q8 sinaliza não finitos, valores não positivos em duração, posição e ids, e negativos em rank, fãs ou BPM; não há teto de rank, e gain negativo é válido.

Em Q11, a faixa 4346251442, “Dirty Bird”, tem data 2026-10-28 (faixa e álbum), posterior à coleta de 16/10; talvez lançamento anunciado, causa não confirmada. Em Q17, os limites são 66,5 a 366,5 s, e as durações vão de 41 a 2.120 s. Em Q18, os limites de rank são −445.721,75 a 1.316.536,25. Evidências: células “Datas, formatos e categorias” e “Possíveis outliers e integridade do enriquecimento”.

Uma ocorrência não tem capa nem lista de faixas do álbum (1/2.800; 0,04%), metadados fora das P1–P4 e do RA2. Em title_version, há 57 nulos e 2.476 vazios: versão não informada, sem motivo para excluir faixa. Evidência: célula “Ausências nulas e textos vazios”.

ID	Verificação e regra	Resultado observado	Evidência
Q1	Ausência em campo essencial às P1–P4 ou RA2	0/2.800 (0,00%)	“Ausências nulas e textos vazios”
Q2	Ausência de preview (nulo ou vazio)	1/2.800 (0,04%)	“Ausências nulas e textos vazios”
Q3	Ausência de title_version (nulo ou vazio)	2.533/2.800 (90,46%)	“Ausências nulas e textos vazios”
Q4	Excedentes por id	219/2.800 (7,82%)	“Duplicidade e limite da chave”
Q5	Excedentes pelo par chart_id_genero e id	0/2.800 (0,00%)	“Duplicidade e limite da chave”
Q6	Linhas inteiras repetidas	0/2.800 (0,00%)	“Duplicidade e limite da chave”
Q7	Tipo divergente do inteiro, real ou booleano esperado	0/2.800 (0,00%)	“Estatísticas descritivas e domínios numéricos”
Q8	Numéricos não finitos, ausentes ou fora do domínio	0/2.800 (0,00%)	“Estatísticas descritivas e domínios numéricos”
Q9	bpm igual a zero (dado não informado)	1.890/2.800 (67,50%)	“Estatísticas descritivas e domínios numéricos”
Q10	gain igual a zero (a avaliar)	27/2.800 (0,96%)	“Estatísticas descritivas e domínios numéricos”
Q11	Data fora de AAAA-MM-DD, inválida ou fora de 1900 até a coleta	1/2.800 (0,04%)	“Datas, formatos e categorias”
Q12	Espaços nas pontas de título, artista ou gênero	1/2.800 (0,04%)	“Datas, formatos e categorias”
Q13	Mais de um nome por id de artista	0/2.800 (0,00%)	“Datas, formatos e categorias”
Q14	Gênero com mais de um nome, ou nome com mais de um id	0/2.800 (0,00%)	“Datas, formatos e categorias”
Q15	Chart geral (id 0), que não é gênero	100/2.800 (3,57%)	“Datas, formatos e categorias”
Q16	Gênero do álbum genérico (id ≤ 0)	11/2.800 (0,39%)	“Datas, formatos e categorias”

ID	Verificação e regra	Resultado observado	Evidência
Q17	Duração fora de Q1 − 1,5 IQR a Q3 + 1,5 IQR	143/2.800 (5,11%)	“Possíveis outliers e integridade do enriquecimento”
Q18	Rank fora de Q1 − 1,5 IQR a Q3 + 1,5 IQR	0/2.800 (0,00%)	“Possíveis outliers e integridade do enriquecimento”
Q19	Id ausente ou divergente na junção faixa/álbum/artista	0/2.800 (0,00%)	“Possíveis outliers e integridade do enriquecimento”
Q20	Duração do chart diferente da de /track	0/2.800 (0,00%)	“Possíveis outliers e integridade do enriquecimento”
Q21	Rank do chart diferente do de /track	0/2.800 (0,00%)	“Possíveis outliers e integridade do enriquecimento”

Impacto dos problemas identificados

Prioridade: preservar os grupos das P1–P4. Q4 não autoriza descartar as 219 ocorrências excedentes; a preparação mantém o vínculo faixa-chart. Q15 exige separar o chart geral dos gêneros, e Q16 mostra que o gênero do álbum não substitui o de origem. Q11 pede decisão para o lançamento futuro não contar nos 12 meses da P2.

Q9 e Q10 são secundários: P1–P4 e o RA2 não usam BPM nem gain. Q12 pede inspecionar antes de padronizar; Q17, revisar os extremos sem excluí-los, pois IQR não prova erro. Q2 não afeta as perguntas.

Q1, Q5–Q8, Q13–Q14 e Q18–Q21 não acharam ocorrências nos testes executados. As decisões estão na seção 04; esta seção não altera df_bruto.

RA1 / 04

Limpeza e preparação

Relacione cada intervenção ao diagnóstico. Justifique tanto os tratamentos realizados quanto as decisões de manter os dados.

Registro das decisões

Decisão e diagnóstico D1 — Preservação das participações nos charts; Q4, Q5 e Q6.

Problema e abrangência

219/2.800 ocorrências excedentes por id, sem duplicata chart-faixa nem linha igual: a faixa aparece em vários charts. Evidência: notebook §3, "Duplicidade e limite da chave".

Tratamento e justificativa

Uma linha por par chart-faixa: excluir pelo id apagaria participações das P1–P4. Nenhum dos 2.800 registros saiu; a chave final inclui a data da coleta.

Implementação notebook §4, célula "Preservação do vínculo entre faixa e chart".

Validação após o tratamento

Chave composta com 0/2.800 duplicatas e 219/2.800 excedentes por id mantidos. Evidência: notebook §5, "Comparação antes e depois da preparação".

Decisão e diagnóstico D2 — Padronização dos espaços em textos; Q12.

Problema e abrangência

1/2.800: "Sona Mohapatra" com espaço não separável no fim. Evidência: notebook §3, "Datas, formatos e categorias".

Tratamento e justificativa

Espaços nas pontas removidos de título, artista e chart, preservando acentos e maiúsculas; um campo mudou, nenhum registro saiu.

Implementação notebook §4, célula "Padronização dos campos textuais".

Validação após o tratamento

Texto antes e depois exibido; de 1/2.800 para 0/2.800. Evidência: notebook §5, "Comparação antes e depois da preparação".

Decisão e diagnóstico D3 — Conversão e sinalização das datas de lançamento; Q11.

Problema e abrangência

1/2.800: faixa 4346251442, "Dirty Bird", lançada em 28/10/2026, após a coleta de 16/10/2026; causa não confirmada. Evidência: notebook §3, "Datas, formatos e categorias".

Tratamento e justificativa

Lançamento convertido para data sem mudar o valor; criados data_coleta (metadados, UTC) e lancamento_posterior_coleta, que separa o futuro dos já ocorridos na P2. Sem exclusão nem estimativa.

Implementação notebook §4, célula "Conversão e validação temporal", e §5, "Padronização dos nomes e tipos".

Validação após o tratamento

2.800 datas convertidas sem perda (formato, calendário e texto conferidos), a futura sinalizada e preservada na releitura. Evidência: notebook §5, "Gravação e releitura do conjunto preparado".

Decisão e diagnóstico D4 — Identificação do chart geral e preservação da origem; Q14, Q15 e Q16.

Problema e abrangência

100/2.800 do chart geral e 11/2.800 com gênero genérico no álbum; ids e nomes de chart consistentes. Evidência: notebook §3, "Datas, formatos e categorias".

Tratamento e justificativa

Id e nome do chart mantidos e tipo_chart (geral ou genero) criado; o geral serve à P3 e o gênero do álbum não substitui a origem das P1–P4. Sem exclusão nem gênero estimado.

Implementação notebook §4, célula "Identificação do chart de origem".

Validação após o tratamento

100/2.800 com id_chart zero como geral e 2.700/2.800 como genero, origens preservadas. Evidência: notebook §5, "Verificações finais do conjunto preparado".

Decisão e diagnóstico D5 — Seleção dos atributos do conjunto preparado; Q2, Q3, Q9 e Q10.

Problema e abrangência

Uma prévia e 2.533 versões ausentes, 1.890 BPM e 27 ganhos zerados, em campos fora das P1–P4 e do RA2. Evidências: notebook §3, "Ausências nulas e textos vazios" e "Estatísticas descritivas e domínios numéricos".

Tratamento e justificativa

12 dos 102 atributos mais quatro de contexto ou qualidade: 16 colunas. Os 90 restantes (prévia, versão, BPM, ganho, álbum) ficam no bruto, sem imputação nem exclusão.

Implementação notebook §5, célula "Seleção e organização dos atributos".

Validação após o tratamento

16 colunas do dicionário, sem nulos nos 2.800 registros, com os campos das P1–P4 e os cinco nomes do gerador do RA2. Evidência: notebook §5, "Verificações finais do conjunto preparado".

Decisão e diagnóstico D6 — Padronização dos nomes e tipos; Q7 e Q8.

Problema e abrangência

Sem problemas de tipo ou domínio nas 2.800, mas nomes da API e datas em texto a organizar. Evidência: notebook §3, "Estatísticas descritivas e domínios numéricos".

Tratamento e justificativa

Nomes em português (rank mantido pelo gerador): oito inteiros, quatro textos, duas datas e dois booleanos. Valores válidos intactos; falha de conversão não vira zero.

Implementação notebook §5, célula "Padronização dos nomes e tipos".

Validação após o tratamento

Inteiros conferidos (ausência, finitude, fração) antes da conversão; domínios, valores e tipos mantidos na releitura. Evidências: notebook §5, "Verificações finais do conjunto preparado" e "Gravação e releitura do conjunto preparado".

Decisão e diagnóstico D7 — Preservação e sinalização dos extremos de duração; Q17 e Q18.

Problema e abrangência

143/2.800 durações fora do IQR (66,5 a 366,5 s) e 0/2.800 ranks. Evidência: notebook §3, "Possíveis outliers e integridade do enriquecimento".

Tratamento e justificativa

Valores mantidos e duracao_fora_limites_iqr criado: extremo não comprova erro, e cortá-lo alteraria a distribuição da P1.

Implementação notebook §4, célula "Sinalização dos extremos de duração".

Validação após o tratamento

143/2.800 sinalizadas pela regra de Q17 e Q18 (seção 03), valores iguais à origem. Evidência: notebook §5, "Verificações finais do conjunto preparado".

Decisão e diagnóstico D8 — Manutenção e revalidação dos dados aprovados; Q1, Q13 e Q19–Q21.

Problema e abrangência

0/2.800 problemas em campos essenciais, nomes por artista e junções (inclusive duração e rank). Evidências: notebook §3, "Ausências nulas e textos vazios", "Datas, formatos e categorias" e "Possíveis outliers e integridade do enriquecimento".

Tratamento e justificativa

Valores aprovados mantidos e testes repetidos, sem imputação; o df_bruto ficou intacto (a preparação usou uma cópia).

Implementação notebook §5, célula "Verificações finais do conjunto preparado".

Validação após o tratamento

2.800 registros aprovados em obrigatórios, chave, domínios, nomes, datas, sinalizações e integridade; valores iguais ao bruto e releitura igual à memória. Evidência: notebook §5, "Gravação e releitura do conjunto preparado".

Resumo das intervenções

Decisão	Ação executada	Impacto nos dados	Evidência
D1	Preservar o vínculo chart-faixa	2.800/2.800 mantidos; 219/2.800 excedentes por id preservados	Notebook §4, "Preservação do vínculo entre faixa e chart"
D2	Remover espaços nas pontas	De 1/2.800 para 0/2.800	Notebook §4, "Padronização dos campos textuais"
D3	Converter e sinalizar datas	2.800 convertidas; 1/2.800 futura mantida e sinalizada	Notebook §4, "Conversão e validação temporal"
D4	Identificar o tipo de chart	100/2.800 do geral identificadas e preservadas	Notebook §4, "Identificação do chart de origem"
D5	Selecionar atributos	12 de origem, 90 não selecionados e quatro novos; 16 finais	Notebook §5, "Seleção e organização dos atributos"
D6	Padronizar nomes e tipos	16 colunas: oito inteiros, quatro textos, duas datas, dois booleanos	Notebook §5, "Padronização dos nomes e tipos"
D7	Sinalizar extremos	143/2.800 sinalizadas, sem exclusão ou alteração	Notebook §4, "Sinalização dos extremos de duração"
D8	Revalidar consistência	2.800/2.800 aprovados pelas regras finais	Notebook §5, "Verificações finais do conjunto preparado"

RA1 / 05

Conjunto de dados resultante

Identifique a saída do RA1 e demonstre sua consistência para uso nas próximas etapas.

Arquivo ou conjunto final dados/preparados/faixas_preparadas.csv, CSV UTF-8, separador vírgula, sem coluna de índice: 2.800 registros, 16 atributos e 367.932 bytes. Evidência: notebook §5, célula "Gravação e releitura do conjunto preparado", e o próprio CSV.

Unidade de observação final uma ocorrência de faixa em um chart de origem na data da coleta, com chave data_coleta, id_chart e id_faixa; a mesma faixa em charts diferentes não é duplicata. Evidência: notebook §5, célula "Verificações finais do conjunto preparado".

Dicionário atualizado dados/preparados/dicionario-faixas.md, com origem, significado, tipo e domínio dos 16 atributos: oito inteiros, quatro textos, duas datas e dois booleanos. rank manteve o nome por compatibilidade com o gerador de eventos; os demais foram padronizados em português. Evidência: notebook §5, célula "Padronização dos nomes e tipos".

Comparação antes e depois

Evidência: notebook §5, célula "Comparação antes e depois da preparação", sobre o retrato de 16/10/2026. As medidas usam 2.800 registros como denominador e podem se sobrepor; não devem ser somadas.

Medida	Após ingestão	Após preparação	Explicação da diferença
Registros	2.800	2.800	Ocorrências preservadas, sem exclusão (D1)
Atributos	102	16	12 atributos de origem e quatro campos de contexto ou qualidade (D5)
Ocorrências com espaços nas pontas	1/2.800 (0,04%)	0/2.800 (0,00%)	Correção textual sem alterar a escrita (D2)
Duplicatas pela chave chart-faixa	0/2.800 (0,00%)	0/2.800 (0,00%)	Unicidade mantida em cada chart e retrato (D1)
Ocorrências excedentes por id da faixa	219/2.800 (7,82%)	219/2.800 (7,82%)	Participações em charts distintos mantidas (D1)
Ocorrências do chart geral	100/2.800 (3,57%)	100/2.800 (3,57%), identificadas	Preservadas e distinguidas pelo tipo de chart (D4)
Lançamentos posteriores à coleta	1/2.800 (0,04%)	1/2.800 (0,04%), sinalizado	Valor da fonte preservado, sem imputar data (D3)
Durações fora dos limites IQR	143/2.800 (5,11%)	143/2.800 (5,11%), sinalizadas	Valores preservados, com sinalização de qualidade (D7)

Verificações finais

Os 2.800 registros passaram nas verificações abaixo (notebook §5, células "Padronização dos nomes e tipos" e "Verificações finais do conjunto preparado"):

- As 16 colunas seguem o dicionário, sem nulos nos campos selecionados.
- A chave data-chart-faixa tem 0/2.800 duplicatas e preserva os vínculos de origem.
- Ids de faixa, artista e álbum, posição e duração são inteiros positivos; id_chart, rank e número de fãs, inteiros não negativos.
- Textos sem vazios nem espaços nas pontas; um nome de chart e um nome de artista por id.
- Datas convertidas sem perda; a data da coleta vem dos metadados, e as sinalizações seguem as regras temporal e IQR.
- Identificadores, duração, rank e fãs mantêm os valores de origem, e as junções com faixa, álbum e artista seguem consistentes.
- O df_bruto, comparado com a cópia anterior à preparação, permaneceu intacto.

O CSV foi relido com tipos informados e datas convertidas, e o relido é igual ao conjunto em memória em 2.800 linhas e 16 colunas (notebook §5, célula "Gravação e releitura do conjunto preparado"). Como CSV não guarda tipos, futuras leituras devem reaplicá-los conforme o dicionário.

Limitações e pendências

O conjunto é o retrato de 16/10/2026, com país aparente US: não é série histórica nem permite comparar países. Evidência: dados/brutos/2026-10-16/metadados.json.

A causa da data futura (1/2.800) não foi confirmada; ela foi preservada e sinalizada, e na P2 não deve contar como lançamento já ocorrido nos 12 meses anteriores à coleta. As 143/2.800 durações fora dos limites IQR também foram mantidas e sinalizadas, pois o critério estatístico não comprova erro. Evidências: notebook §4, células "Conversão e validação temporal" e "Sinalização dos extremos de duração".

BPM, ganho, prévia, versão complementar e outros metadados ficaram fora do CSV, mas seguem no retrato bruto; a seleção não os corrige nem estima. Evidência: notebook §5, célula "Seleção e organização dos atributos".

As 100/2.800 ocorrências do chart geral seguem disponíveis para a P3. Os eventos por gênero do RA2 usam só tipo_chart == "genero", 2.700/2.800 ocorrências; o filtro é aplicado na seção 9. Evidência: notebook §4, célula "Identificação do chart de origem".

RA1 / 06

Organização e reprodutibilidade

Explique como outra pessoa pode obter os dados e executar o fluxo completo do RA1.

Repositório e versão https://github.com/eduardofabrii/data-analytics-ras • ramo main, com o notebook executado, os dados brutos e preparados e as dependências

Ambiente Google Colab (referência) ou Python 3.9 ou mais novo em máquina local • versões mínimas em requirements.txt: pandas 2.2 a 2.x e requests 2.31 ou mais novo (RA1), pyspark 4.0.3 com Java 17 ou mais novo (RA2), jupyter e nbconvert (execução do notebook) • conferidas em 16/10/2026 numa instalação limpa: Python 3.13.16, pandas 2.3.3, requests 2.34.2, pyspark 4.0.3 e nbconvert 7.17.2

Localização dos artefatos

Artefato	Caminho ou forma de obtenção
Dados brutos	dados/brutos/2026-10-16/, versionado: respostas cruas da API em JSON (infos.json, generos.json, charts.json, faixas.json, albuns.json, artistas.json, 57,7 MB) e metadados.json (horário, país aparente US, 6.591 chamadas, 0 erros). Nova coleta só com BAIXAR_DA_API = True na célula "Preparação do ambiente" (primeira célula de código da seção 2)
Código de ingestão e preparação	notebook/ra1-ra2-deezer.ipynb, já executado e com as saídas salvas (ambiente e ingestão na seção 2, a partir da célula "Preparação do ambiente", exploração na 3, limpeza na 4 e transformação na 5)
Dados preparados	dados/preparados/faixas_preparadas.csv (UTF-8, separador vírgula), regravado pelas seções 4 e 5 a cada execução; nunca editado à mão. Colunas descritas em dados/preparados/dicionario-faixas.md
Documentação e dependências	README.md (seções "Execução no Google Colab", "Execução local" e "Dados e resultados esperados"), dados/preparados/dicionario-faixas.md e requirements.txt

Passos para reprodução

A reprodução não depende da API (fora do ar, bloqueada ou com outro chart conforme o país e o dia): o notebook lê por padrão o retrato versionado de 16/10/2026, base dos números deste documento. Uma coleta nova (BAIXAR_DA_API = True) grava outra pasta em dados/brutos/, lida por ser a mais recente, e muda todas as contagens; para voltar ao retrato da entrega, apague a pasta nova ou use um clone limpo.

Ordem	Instrução executável	Resultado esperado
1	Preparar o ambiente. No Colab: *Arquivo → Abrir notebook → GitHub*, repositório eduardofabrii/data-analytics-ras, arquivo notebook/ra1-ra2-deezer.ipynb. Localmente: git clone https://github.com/eduardofabrii/data-analytics-ras.git, cd data-analytics-ras, python -m venv .venv, ativar e pip install -r requirements.txt	No Colab, o notebook abre com o RA1 e o RA2. Localmente, pip e python -c "import pandas, requests" terminam sem erro

Ordem	Instrução executável	Resultado esperado
2	Obter os dados, sem acessar a API: a célula "Preparação do ambiente", na seção 2, clona o repositório no Colab com BAIXAR_DA_API = False, e as células seguintes leem o retrato versionado em dados/brutos/	"Preparação do ambiente" mostra a raiz do projeto; "Leitura do retrato bruto mais recente", dados/brutos/2026-10-16 e os sete JSON
3	Executar do início ao fim. No Colab: *Ambiente de execução* → *Executar tudo*. Localmente: python -m jupyter notebook notebook/ra1-ra2-deezer.ipynb e executar todas as células na ordem, ou jupyter nbconvert --to notebook --execute --inplace notebook/ra1-ra2-deezer.ipynb	Nenhuma célula com erro; na seção 2, df_bruto: 2800 linhas × 102 colunas, 2.581 faixas, 2.292 álbuns, 1.688 artistas e nenhum item sem detalhe ("Verificação do carregamento")
4	Validar a saída: conferir o conjunto preparado e as contagens do RA2	dados/preparados/faixas_preparadas.csv regravado com 2.800 linhas e 16 colunas (seção 5, célula "Gravação e releitura do conjunto preparado"); na seção 11, totais de 30, 60 e 90 reproduções simuladas

Verificação da reprodução

Em 20/10/2026, João Correa, que não escreveu o código das seções, executou o notebook a partir de um clone limpo: ambiente novo com pip install -r requirements.txt e execução com jupyter nbconvert --execute, em Linux (WSL2), Python 3.13.5, pandas 2.3.3, requests 2.34.2, PySpark 4.0.3 e Java 21. Resultado: 47 células de código em sequência, sem erro, em 14 s; df_bruto com 2.800 linhas × 102 colunas; dados/preparados/faixas_preparadas.csv regravado idêntico ao versionado; três lotes de 30 eventos processados (90 reproduções). Em 21/10/2026, o repositório da entrega foi executado de novo do mesmo modo, a partir de um clone limpo, em Linux com Python 3.13.16, pandas 2.3.3 e PySpark 4.0.3: as mesmas 47 células de código sem erro, df_bruto com 2.800 linhas × 102 colunas e o CSV preparado idêntico ao versionado.

RA1 / 07

Referências e anexos

Reúna as fontes utilizadas e os materiais complementares que ajudam a verificar a entrega.

Referências

DEEZER. *Deezer API*: documentação e API pública (/infos, /genre, /chart/{id}/tracks, /track/{id}, /album/{id}, /artist/{id}). 2026. Disponível em: https://developers.deezer.com/api e https://api.deezer.com. Acesso em: 16/10/2026.

ALVES, Rodrigo et al. *DataAudio*: app Flutter que consome a API da Deezer. 2026. Disponível em: https://github.com/rdsalvesPUC/dataaudio. Acesso em: 16/10/2026.

PYTHON SOFTWARE FOUNDATION. *Python 3.13 documentation*. Versão 3.13. Disponível em: https://docs.python.org/3.13/. Acesso em: 16/10/2026.

PANDAS DEVELOPMENT TEAM. *pandas documentation*. Versão 2.3. Disponível em: https://pandas.pydata.org/docs/. Acesso em: 16/10/2026.

REITZ, Kenneth. *Requests: HTTP for Humans*. Versão 2.34. Disponível em: https://requests.readthedocs.io/. Acesso em: 16/10/2026.

PUCPR. Data Analytics. *PjBL – RA1* (enunciado) e *Template_RA1_Data_Analytics.docx*. 2026. Disponível em: Canvas PUCPR (acesso restrito). Acesso em: 15/10/2026.

PUCPR. Data Analytics. Material de aula: *Data Ingestion and Data Quality*, *From Data Preparation to Data Transformation* e *Data Transformation*. 2026. Disponível em: Canvas PUCPR (acesso restrito). Acesso em: 15/10/2026.

Anexos opcionais

Identificação	Conteúdo	Localização
Anexo A	Dicionário do conjunto preparado	dados/preparados/dicionario-faixas.md
Anexo B	Metadados da coleta de 16/10/2026	dados/brutos/2026-10-16/metadados.json

Conferência da entrega

☒ Problema, recorte e perguntas analíticas estão definidos.

☒ Fontes e procedimentos de ingestão estão documentados.

☒ A qualidade foi avaliada com evidências verificáveis.

☒ As decisões de limpeza estão justificadas e validadas.

☒ O conjunto de dados preparado está identificado.

☒ O repositório contém instruções suficientes para reprodução.

☒ Os campos-modelo foram preenchidos e os exemplos revisados.

Identificação do projeto

Título do projeto: Perfil das faixas populares nos charts da Deezer por gênero
Integrantes do grupo: Eduardo Fabri, João Correa, Rodrigo Alves e João Pedro Cardoso
Turma: Bacharelado em Sistemas de Informação • 2º semestre de 2026
Descrição breve do problema ou contexto: os charts da Deezer dizem quais faixas estão no topo de cada gênero, mas não o que elas têm em comum. O projeto coleta esses charts pela API pública da Deezer e prepara os dados para comparar, entre gêneros, a duração das faixas, a idade do lançamento, a popularidade do artista e a concentração de artistas no ranking.

Preencha este notebook ao longo dos dois RAs. Registre decisões e interpretações em poucas frases e acrescente as células de código necessárias em cada etapa.

RA1 — Data Ingestion, Cleaning and Initial Analysis

Nesta etapa, carregue, prepare e explore os dados do projeto.

1. Contexto e objetivo

Apresente brevemente o problema investigado e o que o grupo pretende descobrir com os dados.

Resposta do grupo:

Os charts da Deezer mostram as faixas mais ouvidas em cada gênero, mas não o que elas têm em comum. O grupo quer descrever o perfil dessas faixas e ver se ele muda entre gêneros. O recorte é um único retrato dos charts da Deezer, o chart geral e o de cada gênero, na data da coleta registrada na seção 2. A unidade de observação é a faixa. As perguntas são:

- **P1:** como a duração das faixas varia entre os gêneros;
- **P2:** que parte das faixas de cada gênero foi lançada nos 12 meses anteriores à coleta;
- **P3:** se faixas de artistas com mais fãs têm `rank` mais alto, no geral e dentro de cada gênero;
- **P4:** quantos artistas distintos ocupam cada chart de gênero e que fatia das posições fica com os 5 artistas com mais faixas.

O detalhe do recorte e das lacunas está na seção 01 do documento do RA1.

2. Fonte e ingestão dos dados

- Identifique a fonte dos dados, incluindo link ou referência de acesso.
- Descreva brevemente o dataset e o que seus registros representam.
- Explique como os dados foram carregados e implemente a ingestão.

Resposta do grupo:

A fonte é a API pública da Deezer (`https://api.deezer.com`, documentação em `https://developers.deezer.com/api`), acessada sem autenticação e sem chave. Coletamos os charts de faixas mais tocadas: o chart geral e um chart por gênero da lista `/genre`. Cada registro do `df_bruto` é um item de um chart, ou seja, uma faixa na posição em que apareceu em um chart de origem; a mesma faixa pode aparecer em mais de um chart, e essas repetições ficam no bruto. Cada item recebe os campos extras da faixa (`/track/{id}`, como `bpm`, `isrc` e `release_date`), do álbum (`/album/{id}`, como gênero, gravadora e data de lançamento) e do artista (`/artist/{id}`, como `nb_fan` e `nb_album`), juntados pelo id.

A ingestão é feita por código nas células abaixo: as chamadas passam por uma função com pausa entre requisições, novas tentativas e tratamento do objeto `error`, que a API devolve mesmo com HTTP 200. Os charts são paginados por `index` e `limit`. As respostas são gravadas cruas no retrato bruto `dados/brutos/AAAA-MM-DD/`, com um `metadados.json` da coleta, e o notebook lê esse retrato por padrão (`BAIXAR_DA_API = False`), para que os números sejam os mesmos em toda execução.

O retrato usado é o de 16/10/2026 (país aparente US): 6.591 chamadas, sem erros, 28 charts de 100 itens (o geral e 27 gêneros). O `df_bruto` tem 2.800 linhas e 102 colunas, com 2.581 faixas, 2.292 álbuns e 1.688 artistas únicos, todos com o detalhe juntado.

```
# Preparação do ambiente: bibliotecas, pastas do projeto e origem dos dados
import subprocess
import sys
from pathlib import Path
```

```
import pandas as pd

URL_REPOSITORIO = "https://github.com/eduardofabrii/data-analytics-ras.git"
PASTA_CLONE = "data-analytics-ras"
RAMO = "main"  # no Colab, troque pelo ramo do repositório que quiser executar
NO_COLAB = "google.colab" in sys.modules

if NO_COLAB:
    if Path(PASTA_CLONE).exists():
        # Clone de uma execução anterior nesta sessão do Colab: traz a versão mais nova do ramo
        subprocess.run(["git", "-C", PASTA_CLONE, "pull", "-q", "origin", RAMO], check=False)
    else:
        subprocess.run(["git", "clone", "-q", "-b", RAMO, URL_REPOSITORIO], check=True)

# A raiz é a pasta que contém o requirements.txt e os dados brutos (funciona no Colab, na raiz ou dentro de
notebook/)
candidatos = [Path(PASTA_CLONE), Path.cwd(), Path.cwd().parent]
RAIZ = next(
    (p.resolve() for p in candidatos if (p / "requirements.txt").exists() and (p / "dados" / "brutos").is_dir()),
    None,
)
if RAIZ is None:
    raise FileNotFoundError(
        "Raiz do repositório não encontrada (pasta com o requirements.txt e dados/brutos). "
        "Rode o notebook de dentro do clone "
        f"(raiz ou notebook/) ou, no Colab, confira se o ramo '{RAMO}' já tem a estrutura do projeto."
    )

PASTA_BRUTOS = RAIZ / "dados" / "brutos"
PASTA_PREPARADOS = RAIZ / "dados" / "preparados"
PASTA_STREAMING = RAIZ / "dados" / "streaming"
for pasta in (PASTA_BRUTOS, PASTA_PREPARADOS, PASTA_STREAMING):
    pasta.mkdir(parents=True, exist_ok=True)

# False: lê o retrato bruto versionado no repositório. True: coleta de novo na API da Deezer.
BAIXAR_DA_API = False

pd.set_option("display.max_columns", 30)
pd.set_option("display.width", 120)
print(f"Raiz do projeto: {RAIZ.name}")  # só o nome da pasta: o caminho completo é da máquina de quem executa
print(f"Ambiente: {'Google Colab' if NO_COLAB else 'local'} · Python {sys.version.split()[0]} · pandas
{pd.__version__}")
```

```
Raiz do projeto: data-analytics-ras
Ambiente: Google Colab · Python 3.13.16 · pandas 2.2.3
```

```
# Parâmetros da coleta e acesso à API
import json
import platform
import time
from datetime import datetime, timezone

import requests
from IPython.display import display

URL_API = "https://api.deezer.com"
LIMITE_PAGINA = 100       # itens por página do chart (parâmetro limit)
TETO_POR_CHART = 300      # máximo de itens lidos por chart, mesmo que a API ofereça mais
PAUSA_S = 0.15            # pausa entre chamadas; a API aceita cerca de 50 chamadas a cada 5 s
TENTATIVAS = 4            # tentativas por chamada antes de registrar o erro
TIMEOUT_S = 20

sessao = requests.Session()
registro = {"chamadas": 0, "chamadas_por_endpoint": {}, "novas_tentativas": 0, "erros": []}


def chamar_api(caminho, endpoint, **params):
    """GET em URL_API + caminho. Devolve o JSON da resposta ou None, registrando o erro.

    A Deezer devolve falhas como {"error": {...}} com HTTP 200: o código 4 (limite de chamadas)
    e falhas de rede ganham nova tentativa com espera crescente; os demais erros são registrados.
    """
    ultimo_erro = None
    for tentativa in range(1, TENTATIVAS + 1):
```

```
        time.sleep(PAUSA_S)
        registro["chamadas"] += 1
        registro["chamadas_por_endpoint"][endpoint] = registro["chamadas_por_endpoint"].get(endpoint, 0) + 1
        try:
            resposta = sessao.get(URL_API + caminho, params=params, timeout=TIMEOUT_S)
            resposta.raise_for_status()
            corpo = resposta.json()
        except (requests.RequestException, ValueError) as erro:
            ultimo_erro = {"tipo": type(erro).__name__, "mensagem": str(erro)[:200]}
        else:
            if not (isinstance(corpo, dict) and "error" in corpo):
                return corpo
            ultimo_erro = {"tipo": corpo["error"].get("type"), "codigo": corpo["error"].get("code"),
                           "mensagem": corpo["error"].get("message")}
            if ultimo_erro["codigo"] != 4:   # objeto inexistente ou parâmetro inválido: repetir não resolve
                break
        if tentativa < TENTATIVAS:
            registro["novas_tentativas"] += 1
            time.sleep(2 ** tentativa)
    registro["erros"].append({"caminho": caminho, "parametros": params, **ultimo_erro})
    return None


print(f"API: {URL_API} · limit={LIMITE_PAGINA} · teto por chart={TETO_POR_CHART} · pausa={PAUSA_S} s")
print(f"Coletar de novo na API: {BAIXAR_DA_API}")
```

```
API: https://api.deezer.com · limit=100 · teto por chart=300 · pausa=0.15 s
Coletar de novo na API: False
```

```
# Coleta dos charts por gênero
if BAIXAR_DA_API:
    inicio_coleta = datetime.now(timezone.utc)
    infos = chamar_api("/infos", "/infos")   # país de onde a API enxerga a requisição

    resposta_generos = chamar_api("/genre", "/genre")
    if resposta_generos is None:
        raise RuntimeError(f"A API não devolveu a lista de gêneros: {registro['erros'][-1]}")
    generos = {g["id"]: g["name"] for g in resposta_generos["data"]}
    generos.setdefault(0, "All")   # chart geral

    charts = []
    for id_genero, nome_genero in generos.items():
        paginas = []
        for index in range(0, TETO_POR_CHART, LIMITE_PAGINA):
            pagina = chamar_api(f"/chart/{id_genero}/tracks", "/chart/{id}/tracks",
                                index=index, limit=LIMITE_PAGINA)
            if pagina is None:
                break
            paginas.append({"index": index, "limit": LIMITE_PAGINA, "resposta": pagina})
            lidos = len(pagina.get("data", []))
            if lidos < LIMITE_PAGINA or index + lidos >= pagina.get("total", index + lidos):
                break   # última página do chart
        charts.append({"id_genero": id_genero, "nome_genero": nome_genero, "paginas": paginas})
        itens = sum(len(p["resposta"].get("data", [])) for p in paginas)
        print(f"Chart {id_genero:>4} ({nome_genero}): {itens} itens em {len(paginas)} página(s)")
    print(f"{len(charts)} charts coletados em {registro['chamadas']} chamadas")
```

```
# Coleta dos detalhes de faixas, álbuns e artistas
if BAIXAR_DA_API:
    itens_chart = [item for c in charts for p in c["paginas"] for item in p["resposta"].get("data", [])]
    ids_faixas = sorted({item["id"] for item in itens_chart})
    ids_albuns = sorted({item["album"]["id"] for item in itens_chart if item.get("album")})
    ids_artistas = sorted({item["artist"]["id"] for item in itens_chart if item.get("artist")})
    print(f"{len(itens_chart)} itens nos charts · {len(ids_faixas)} faixas únicas · {len(ids_albuns)} álbuns únicos"
          f" · {len(ids_artistas)} artistas únicos")

    faixas = {}
    for i, id_faixa in enumerate(ids_faixas, 1):
        faixas[str(id_faixa)] = chamar_api(f"/track/{id_faixa}", "/track/{id}")
        if i % 250 == 0:
            print(f"  faixas: {i}/{len(ids_faixas)}")
    albuns = {}
    for i, id_album in enumerate(ids_albuns, 1):
        albuns[str(id_album)] = chamar_api(f"/album/{id_album}", "/album/{id}")
```

```
        if i % 250 == 0:
            print(f"  álbuns: {i}/{len(ids_albuns)}")
    artistas = {}
    for i, id_artista in enumerate(ids_artistas, 1):
        artistas[str(id_artista)] = chamar_api(f"/artist/{id_artista}", "/artist/{id}")
        if i % 250 == 0:
            print(f"  artistas: {i}/{len(ids_artistas)}")
    fim_coleta = datetime.now(timezone.utc)
    print(f"Coleta terminada: {registro['chamadas']} chamadas, {len(registro['erros'])} erro(s)")
```

```
# Gravação do retrato bruto
if BAIXAR_DA_API:
    pasta_retrato = PASTA_BRUTOS / inicio_coleta.strftime("%Y-%m-%d")
    pasta_retrato.mkdir(parents=True, exist_ok=True)
    conteudo = {"infos.json": infos, "generos.json": resposta_generos, "charts.json": charts,
                "faixas.json": faixas, "albuns.json": albuns, "artistas.json": artistas}
    for nome, dados in conteudo.items():
        # Respostas cruas da API, sem nenhuma alteração; JSON compacto para o retrato caber no repositório
        (pasta_retrato / nome).write_text(json.dumps(dados, ensure_ascii=False, separators=(",", ":")),
                                          encoding="utf-8")
    metadados = {
        "inicio_utc": inicio_coleta.isoformat(timespec="seconds"),
        "fim_utc": fim_coleta.isoformat(timespec="seconds"),
        "url_api": URL_API,
        "pais_aparente": (infos or {}).get("country_iso"),
        "endpoints": ["/infos", "/genre", "/chart/{id}/tracks", "/track/{id}", "/album/{id}", "/artist/{id}"],
        "parametros": {"limit": LIMITE_PAGINA, "teto_por_chart": TETO_POR_CHART, "pausa_s": PAUSA_S,
                       "tentativas": TENTATIVAS, "timeout_s": TIMEOUT_S},
        "chamadas": registro["chamadas"],
        "chamadas_por_endpoint": registro["chamadas_por_endpoint"],
        "novas_tentativas": registro["novas_tentativas"],
        "quantidade_erros": len(registro["erros"]),
        "erros": registro["erros"],
        "charts": len(charts),
        "itens_chart": len(itens_chart),
        "faixas_unicas": len(ids_faixas),
        "albuns_unicos": len(ids_albuns),
        "artistas_unicos": len(ids_artistas),
        "arquivos": sorted(conteudo) + ["metadados.json"],
        "ambiente": {"python": platform.python_version(), "pandas": pd.__version__,
                     "requests": requests.__version__, "colab": NO_COLAB},
    }
    (pasta_retrato / "metadados.json").write_text(json.dumps(metadados, ensure_ascii=False, indent=2),
                                                  encoding="utf-8")
    tamanho_mb = sum(a.stat().st_size for a in pasta_retrato.iterdir()) / 1e6
    print(f"Retrato gravado em {pasta_retrato.relative_to(RAIZ)} ({tamanho_mb:.1f} MB)")
```

```
# Leitura do retrato bruto mais recente
retratos = sorted(p for p in PASTA_BRUTOS.glob("????-??-??") if (p / "metadados.json").exists())
if not retratos:
    raise FileNotFoundError(
        f"Nenhum retrato bruto em {PASTA_BRUTOS}. Atualize o clone do repositório ou rode a primeira célula da seção
2 "
        "com BAIXAR_DA_API = True para coletar na API da Deezer."
    )
PASTA_RETRATO = retratos[-1]


def ler_json(nome):
    return json.loads((PASTA_RETRATO / nome).read_text(encoding="utf-8"))


metadados = ler_json("metadados.json")
charts = ler_json("charts.json")
faixas = ler_json("faixas.json")
albuns = ler_json("albuns.json")
artistas = ler_json("artistas.json")
print(f"Retrato lido: {PASTA_RETRATO.relative_to(RAIZ)} ({len(retratos)} retrato(s) disponível(is))")
for arquivo in sorted(PASTA_RETRATO.iterdir()):
    print(f"  {arquivo.name:<15} {arquivo.stat().st_size / 1e6:6.2f} MB")
```

```
Retrato lido: dados/brutos/2026-10-16 (1 retrato(s) disponível(is))
  albuns.json      37.17 MB
  artistas.json     1.47 MB
```

```
charts.json       5.65 MB
faixas.json      13.35 MB
generos.json      0.02 MB
infos.json        0.00 MB
metadados.json    0.00 MB
```

```
# Metadados do retrato lido
resumo_metadados = pd.Series({
    "Início da coleta (UTC)": metadados["inicio_utc"],
    "Fim da coleta (UTC)": metadados["fim_utc"],
    "País aparente da requisição": metadados["pais_aparente"],
    "Endpoints": ", ".join(metadados["endpoints"]),
    "Parâmetros": ", ".join(f"{k}={v}" for k, v in metadados["parametros"].items()),
    "Chamadas à API": metadados["chamadas"],
    "Novas tentativas": metadados["novas_tentativas"],
    "Erros registrados": metadados["quantidade_erros"],
    "Charts coletados": metadados["charts"],
    "Itens nos charts": metadados["itens_chart"],
    "Faixas únicas": metadados["faixas_unicas"],
    "Álbuns únicos": metadados["albuns_unicos"],
    "Artistas únicos": metadados["artistas_unicos"],
    "Ambiente da coleta": ", ".join(f"{k} {v}" for k, v in metadados["ambiente"].items()),
}, name="valor")
display(resumo_metadados.to_frame())
display(pd.Series(metadados["chamadas_por_endpoint"], name="chamadas").to_frame())
if metadados["erros"]:
    display(pd.DataFrame(metadados["erros"]))
```

	valor
Início da coleta (UTC)	2026-10-16T21:03:16+00:00
Fim da coleta (UTC)	2026-10-16T21:41:09+00:00
País aparente da requisição	US
Endpoints	/infos, /genre, /chart/{id}/tracks, /track/{id}...
Parâmetros	limit=100, teto_por_chart=300, pausa_s=0.15, t...
Chamadas à API	6591
Novas tentativas	0
Erros registrados	0
Charts coletados	28
Itens nos charts	2800
Faixas únicas	2581
Álbuns únicos	2292
Artistas únicos	1688
Ambiente da coleta	python 3.13.16, pandas 2.3.3, requests 2.34.2,...

	chamadas
/infos	1
/genre	1
/chart/{id}/tracks	28
/track/{id}	2581
/album/{id}	2292
/artist/{id}	1688

```
# Montagem do df_bruto
linhas = []
for chart in charts:
    ordem = 0
    for pagina in chart["paginas"]:
        for item in pagina["resposta"].get("data", []):
```

```
            ordem += 1
            linhas.append({"chart_id_genero": chart["id_genero"], "chart_nome_genero": chart["nome_genero"],
                           "chart_ordem": ordem, **item})
itens = pd.json_normalize(linhas, sep="_")


def campos_simples(objeto, prefixo, ignorar=()):
    """Campos de primeiro nível de uma resposta (objetos aninhados ficam de fora; listas ficam como vieram)."""
    return {f"{prefixo}{k}": v for k, v in objeto.items() if not isinstance(v, dict) and k not in ignorar}


detalhe_faixas = pd.DataFrame([campos_simples(f, "detalhe_faixa_") for f in faixas.values() if f])
detalhe_albuns = pd.DataFrame([
    {**campos_simples(a, "detalhe_album_", ignorar=("tracks",)),
     "detalhe_album_genres": (a.get("genres") or {}).get("data")}
    for a in albuns.values() if a
])
detalhe_artistas = pd.DataFrame([campos_simples(a, "detalhe_artista_") for a in artistas.values() if a])

df_bruto = (
    itens
    .merge(detalhe_faixas, how="left", left_on="id", right_on="detalhe_faixa_id")
    .merge(detalhe_albuns, how="left", left_on="album_id", right_on="detalhe_album_id")
    .merge(detalhe_artistas, how="left", left_on="artist_id", right_on="detalhe_artista_id")
)
print(f"df_bruto: {df_bruto.shape[0]} linhas × {df_bruto.shape[1]} colunas")
```

```
df_bruto: 2800 linhas × 102 colunas
```

```
# Verificação do carregamento
origem_colunas = pd.Series(
    ["chart" if c.startswith("chart_") else "detalhe da faixa" if c.startswith("detalhe_faixa_")
     else "detalhe do álbum" if c.startswith("detalhe_album_")
     else "detalhe do artista" if c.startswith("detalhe_artista_") else "item do chart" for c in df_bruto.columns]
).value_counts().rename("colunas")
print(f"Linhas: {len(df_bruto)} (itens nos charts segundo os metadados: {metadados['itens_chart']})")
print(f"Faixas únicas: {df_bruto['id'].nunique()} · álbuns únicos: {df_bruto['album_id'].nunique()} · "
      f"artistas únicos: {df_bruto['artist_id'].nunique()}")
print(f"Itens sem detalhe da faixa: {df_bruto['detalhe_faixa_id'].isna().sum()} · "
      f"sem detalhe do álbum: {df_bruto['detalhe_album_id'].isna().sum()} · "
      f"sem detalhe do artista: {df_bruto['detalhe_artista_id'].isna().sum()}")
display(origem_colunas.to_frame())
display(df_bruto.groupby(["chart_id_genero", "chart_nome_genero"]).size().rename("itens").to_frame())
display(df_bruto.head())
```

```
Linhas: 2800 (itens nos charts segundo os metadados: 2800)
Faixas únicas: 2581 · álbuns únicos: 2292 · artistas únicos: 1688
Itens sem detalhe da faixa: 0 · sem detalhe do álbum: 0 · sem detalhe do artista: 0
```

	colunas
item do chart	35
detalhe do álbum	26
detalhe da faixa	24
detalhe do artista	14
chart	3

		itens
chart_id_genero	**chart_nome_genero**	
0	**All**	100
2	**African Music**	100
16	**Asian Music**	100
65	**Traditional Mexicano**	100
67	**Salsa**	100
71	**Cumbia**	100
75	**Brazilian Music**	100

		itens
chart_id_genero	**chart_nome_genero**	
81	**Indian Music**	100
84	**Country**	100
85	**Alternative**	100
95	**Kids**	100
98	**Classical**	100
106	**Electro**	100
113	**Dance**	100
116	**Rap/Hip Hop**	100
122	**Reggaeton**	100
129	**Jazz**	100
132	**Pop**	100
144	**Reggae**	100
152	**Rock**	100
153	**Blues**	100
165	**R&B**	100
169	**Soul & Funk**	100
173	**Films/Games**	100
186	**Christian**	100
197	**Latin Music**	100
464	**Metal**	100
466	**Folk**	100

	chart_id_genero	chart_nome_genero	chart_ordem	id	title	title_short	title_version
0	0	All	1	3818963601	Dracula (with JENNIE)	Dracula (with JENNIE)	
1	0	All	2	3895241341	Boston	Boston	
2	0	All	3	3834003271	Be Her	Be Her	
3	0	All	4	3602074142	Choosin' Texas	Choosin' Texas	
4	0	All	5	4167204822	Been By Now	Been By Now	

	link	duration	rank	explicit_lyrics	explicit_content_lyrics
0	https://www.deezer.com/track/3818963601	209	982905	True	0
1	https://www.deezer.com/track/3895241341	170	873262	False	0
2	https://www.deezer.com/track/3834003271	217	805867	False	0
3	https://www.deezer.com/track/3602074142	232	978085	False	0
4	https://www.deezer.com/track/4167204822	213	768651	False	0

	explicit_content_cover	preview	md5_image	...
0	0	https://cdnt-preview.dzcdn.net/api/1/1/6/2/5/0...	b868399da682f34dcd7d98af1c0de80b	...
1	0	https://cdnt-preview.dzcdn.net/api/1/1/a/d/f/0...	66d6baca9df5092af22a710ce10d39cf	...
2	0	https://cdnt-preview.dzcdn.net/api/1/1/f/1/4/0...	b1bde069e57968a190b0506aef2b6e3e	...

	explicit_content_cover	preview	md5_image	...
3	0	https://cdnt-preview.dzcdn.net/api/1/1/5/b/5/0...	749ad2ad7609ec768e342bec41078095	...
4	0	https://cdnt-preview.dzcdn.net/api/1/1/b/5/4/0...	38e835566214fba0d9f0c71d58e16145	...

	detalhe_album_genres	detalhe_artista_id	detalhe_artista_name	detalhe_artista_link
0	[{'id': 85, 'name': 'Alternative', 'picture': ...	134790	Tame Impala	https://www.deezer.com/artist/134790
1	[{'id': 84, 'name': 'Country', 'picture': 'htt...	181157207	STELLA LEFTY	https://www.deezer.com/artist/181157207
2	[{'id': 84, 'name': 'Country', 'picture': 'htt...	14867123	Ella Langley	https://www.deezer.com/artist/14867123
3	[{'id': 84, 'name': 'Country', 'picture': 'htt...	14867123	Ella Langley	https://www.deezer.com/artist/14867123
4	[{'id': 84, 'name': 'Country', 'picture': 'htt...	7188840	Morgan Wallen	https://www.deezer.com/artist/7188840

	detalhe_artista_share	detalhe_artista_picture
0	https://www.deezer.com/artist/134790?utm_sourc...	https://api.deezer.com/artist/134790/image
1	https://www.deezer.com/artist/181157207?utm_so...	https://api.deezer.com/artist/181157207/image
2	https://www.deezer.com/artist/14867123?utm_sou...	https://api.deezer.com/artist/14867123/image
3	https://www.deezer.com/artist/14867123?utm_sou...	https://api.deezer.com/artist/14867123/image
4	https://www.deezer.com/artist/7188840?utm_sour...	https://api.deezer.com/artist/7188840/image

	detalhe_artista_picture_small	detalhe_artista_picture_medium	detalhe_artista_picture_big
0	https://cdn-images.dzcdn.net/images/artist/879...	https://cdn-images.dzcdn.net/images/artist/879...	https://cdn-images.dzcdn.net/images/artist/879...
1	https://cdn-images.dzcdn.net/images/artist/67c...	https://cdn-images.dzcdn.net/images/artist/67c...	https://cdn-images.dzcdn.net/images/artist/67c...
2	https://cdn-images.dzcdn.net/images/artist/77a...	https://cdn-images.dzcdn.net/images/artist/77a...	https://cdn-images.dzcdn.net/images/artist/77a...
3	https://cdn-images.dzcdn.net/images/artist/77a...	https://cdn-images.dzcdn.net/images/artist/77a...	https://cdn-images.dzcdn.net/images/artist/77a...
4	https://cdn-images.dzcdn.net/images/artist/997...	https://cdn-images.dzcdn.net/images/artist/997...	https://cdn-images.dzcdn.net/images/artist/997...

	detalhe_artista_picture_xl	detalhe_artista_nb_album	detalhe_artista_nb_fan	detalhe_artista_radio
0	https://cdn-images.dzcdn.net/images/artist/879...	41	1152208	True
1	https://cdn-images.dzcdn.net/images/artist/67c...	18	3583	True
2	https://cdn-images.dzcdn.net/images/artist/77a...	28	33537	True
3	https://cdn-images.dzcdn.net/images/artist/77a...	28	33537	True
4	https://cdn-images.dzcdn.net/images/artist/997...	47	304123	True

	detalhe_artista_tracklist	detalhe_artista_type
0	https://api.deezer.com/artist/134790/top?limit=50	artist
1	https://api.deezer.com/artist/181157207/top?li...	artist
2	https://api.deezer.com/artist/14867123/top?lim...	artist

	detalhe_artista_tracklist	detalhe_artista_type
3	https://api.deezer.com/artist/14867123/top?lim...	artist
4	https://api.deezer.com/artist/7188840/top?limi...	artist

5 rows × 102 columns

3. Exploração inicial dos dados

Investigue a quantidade de registros e colunas, os tipos de dados, os valores ausentes e outras características relevantes da base.

```
# Visão geral e tipos observados
import json
import numpy as np
import pandas as pd
from IPython.display import display

numero_linhas = len(df_bruto)
if numero_linhas == 0:
    raise ValueError("O diagnóstico exige um df_bruto não vazio; execute a seção 2.")
print(f"Retrato: {numero_linhas} linhas × {df_bruto.shape[1]} colunas; "
      f"{df_bruto['id'].nunique()} faixas; {df_bruto['chart_id_genero'].nunique()} charts.")
print(f"Memória, incluindo objetos: {df_bruto.memory_usage(deep=True).sum():,} bytes.")
inventario = df_bruto.dtypes.astype(str).rename("tipo_observado").to_frame()
display(inventario.reset_index(names="atributo"))
```

```
Retrato: 2800 linhas × 102 colunas; 2581 faixas; 28 charts.
Memória, incluindo objetos: 25,886,539 bytes.
```

	atributo	tipo_observado
0	chart_id_genero	int64
1	chart_nome_genero	object
2	chart_ordem	int64
3	id	int64
4	title	object
...	...	...
97	detalhe_artista_nb_album	int64
98	detalhe_artista_nb_fan	int64
99	detalhe_artista_radio	bool
100	detalhe_artista_tracklist	object
101	detalhe_artista_type	object

102 rows × 2 columns

```
# Ausências nulas e textos vazios
# isna() encontra nulos. Para textos, também contamos vazio e espaços como ausência.
mascara_ausencias = df_bruto.isna()
textos_vazios = pd.DataFrame(False, index=df_bruto.index, columns=df_bruto.columns)

for coluna in df_bruto.columns:
    if pd.api.types.is_string_dtype(df_bruto[coluna].dropna()):
        textos_vazios[coluna] = df_bruto[coluna].str.strip().eq("").fillna(False)
        mascara_ausencias[coluna] = mascara_ausencias[coluna] | textos_vazios[coluna]

ausencias = pd.DataFrame({
    "nulos": df_bruto.isna().sum(),
    "textos_vazios": textos_vazios.sum(),
    "total_ausentes": mascara_ausencias.sum(),
})
ausencias["percentual"] = 100 * ausencias["total_ausentes"] / numero_linhas
display(ausencias.reset_index(names="atributo"))
```

	atributo	nulos	textos_vazios	total_ausentes	percentual
0	chart_id_genero	0	0	0	0.0
1	chart_nome_genero	0	0	0	0.0
2	chart_ordem	0	0	0	0.0
3	id	0	0	0	0.0
4	title	0	0	0	0.0
...	...	...	...	...	...
97	detalhe_artista_nb_album	0	0	0	0.0
98	detalhe_artista_nb_fan	0	0	0	0.0
99	detalhe_artista_radio	0	0	0	0.0
100	detalhe_artista_tracklist	0	0	0	0.0
101	detalhe_artista_type	0	0	0	0.0

102 rows × 5 columns

```
# Duplicidade e limite da chave
# Algumas colunas guardam listas. Só para comparar linhas, transformamos listas em texto.
# df_bruto continua intacto: a comparação usa outra tabela.
def texto_para_comparacao(valor):
    if isinstance(valor, (list, dict)):
        return json.dumps(valor, ensure_ascii=False, sort_keys=True)
    return valor

tabela_comparacao = df_bruto.copy()
for coluna in tabela_comparacao.columns:
    tabela_comparacao[coluna] = tabela_comparacao[coluna].map(texto_para_comparacao)

duplicadas_inteiras = tabela_comparacao.duplicated()
duplicadas_id = df_bruto.duplicated("id")
duplicadas_chart = df_bruto.duplicated(["chart_id_genero", "id"])
print(f"Ocorrências excedentes por id: {duplicadas_id.sum()}/{numero_linhas}; "
      f"por par chart-faixa: {duplicadas_chart.sum()}/{numero_linhas}; "
      f"linhas inteiras iguais: {duplicadas_inteiras.sum()}/{numero_linhas}.")
```

```
Ocorrências excedentes por id: 219/2800; por par chart-faixa: 0/2800; linhas inteiras iguais: 0/2800.
```

```
# Estatísticas descritivas e domínios numéricos
colunas_numericas = ["duration", "rank", "position", "detalhe_faixa_bpm",
                     "detalhe_faixa_gain", "detalhe_artista_nb_fan"]
numericos = df_bruto[colunas_numericas].apply(pd.to_numeric, errors="coerce")
display(numericos.describe().T)
# São regras de integridade, não indicadores analíticos das perguntas P1 a P4.
colunas_inteiras = ["id", "chart_id_genero", "chart_ordem", "duration", "rank", "position",
                    "artist_id", "album_id", "detalhe_faixa_id", "detalhe_album_id",
                    "detalhe_artista_id", "detalhe_artista_nb_fan"]
tipos_invalidos = pd.Series(False, index=df_bruto.index)
for coluna in colunas_inteiras:
    valores = pd.to_numeric(df_bruto[coluna], errors="coerce")
    tipos_invalidos |= valores.isna() | ~np.isfinite(valores) | valores.mod(1).ne(0)
# Strings conversíveis também são divergências do tipo esperado, mesmo sem perda na conversão.
for coluna in colunas_inteiras + ["detalhe_faixa_bpm", "detalhe_faixa_gain"]:
    tipos_invalidos |= ~df_bruto[coluna].map(
        lambda valor: isinstance(valor, (int, float, np.integer, np.floating))
        and not isinstance(valor, (bool, np.bool_))
    )
tipos_invalidos |= ~df_bruto["explicit_lyrics"].map(lambda valor: isinstance(valor, (bool, np.bool_)))
# Cada comparação devolve True nas linhas com problema.
invalidos_numericos = numericos.isna().any(axis=1) | ~np.isfinite(numericos).all(axis=1)
invalidos_numericos = invalidos_numericos | (numericos["duration"] <= 0)
invalidos_numericos = invalidos_numericos | (numericos["position"] <= 0)
invalidos_numericos = invalidos_numericos | (numericos["rank"] < 0)
invalidos_numericos = invalidos_numericos | (numericos["detalhe_artista_nb_fan"] < 0)
invalidos_numericos = invalidos_numericos | (numericos["detalhe_faixa_bpm"] < 0)
for coluna in ["id", "artist_id", "album_id"]:
```

```
    valores = pd.to_numeric(df_bruto[coluna], errors="coerce")
    invalidos_numericos = invalidos_numericos | (valores <= 0)
bpm_zero = numericos["detalhe_faixa_bpm"] == 0
gain_zero = numericos["detalhe_faixa_gain"] == 0
# gain é um ajuste em dB: negativo é permitido; zero é sinalizado para avaliação, não prova de erro.
```

	count	mean	std	min	25%	50%	75%
duration	2800.0	2.284300e+02	9.743114e+01	41.0	179.00	213.0	254.00
rank	2800.0	4.480146e+05	2.715404e+05	807.0	215125.00	446784.5	655689.50
position	2800.0	5.050000e+01	2.887123e+01	1.0	25.75	50.5	75.25
detalhe_faixa_bpm	2800.0	4.285188e+01	6.408310e+01	0.0	0.00	0.0	104.93
detalhe_faixa_gain	2800.0	-1.053176e+01	3.643281e+00	-30.7	-12.30	-9.7	-8.10
detalhe_artista_nb_fan	2800.0	1.188450e+06	2.872902e+06	0.0	5530.00	65163.0	732200.00

	max
duration	2120.0
rank	999724.0
position	100.0
detalhe_faixa_bpm	240.4
detalhe_faixa_gain	2.1
detalhe_artista_nb_fan	24109325.0

```
# Datas, formatos e categorias
colunas_datas = ["detalhe_faixa_release_date", "detalhe_album_release_date"]
# A data de comparação vem dos metadados da coleta, para repetir o mesmo resultado depois.
data_coleta = pd.Timestamp(metadados["inicio_utc"]).date()
datas_invalidas = pd.Series(False, index=df_bruto.index)
for coluna in colunas_datas:
    texto = df_bruto[coluna].astype("string")
    formato_correto = texto.str.fullmatch(r"\d{4}-\d{2}-\d{2}").fillna(False)
    datas = pd.to_datetime(texto, format="%Y-%m-%d", errors="coerce")
    problema = ~formato_correto | datas.isna()
    problema = problema | (datas < pd.Timestamp("1900-01-01"))
    problema = problema | (datas > pd.Timestamp(data_coleta))
    datas_invalidas = datas_invalidas | problema

espacos = pd.Series(False, index=df_bruto.index)
for coluna in ["title", "artist_name", "chart_nome_genero"]:
    texto = df_bruto[coluna].astype("string")
    espacos = espacos | texto.ne(texto.str.strip()).fillna(False)
nomes_por_artista = df_bruto.groupby("artist_id")["artist_name"].nunique()
variacoes_artista = df_bruto["artist_id"].isin(nomes_por_artista[nomes_por_artista.gt(1)].index)
nomes_por_genero = df_bruto.groupby("chart_id_genero")["chart_nome_genero"].nunique()
categorias_inconsistentes = df_bruto["chart_id_genero"].isin(nomes_por_genero[nomes_por_genero.gt(1)].index)
nomes_normalizados = df_bruto["chart_nome_genero"].astype("string").str.strip().str.casefold()
ids_por_nome = df_bruto.groupby(nomes_normalizados)["chart_id_genero"].nunique()
categorias_inconsistentes |= nomes_normalizados.isin(ids_por_nome[ids_por_nome.gt(1)].index)
chart_geral = df_bruto["chart_id_genero"].eq(0)
genero_album_generico = pd.to_numeric(df_bruto["detalhe_album_genre_id"], errors="coerce").le(0)
```

```
# Possíveis outliers e integridade do enriquecimento
# Limites IQR são sinais para inspeção; extremos não são removidos.
limites_outliers = []
for coluna in ["duration", "rank"]:
    primeiro_quartil, terceiro_quartil = numericos[coluna].quantile([0.25, 0.75])
    amplitude = terceiro_quartil - primeiro_quartil
    inferior, superior = primeiro_quartil - 1.5 * amplitude, terceiro_quartil + 1.5 * amplitude
    mascara = numericos[coluna].lt(inferior) | numericos[coluna].gt(superior)
    limites_outliers.append({"atributo": coluna, "inferior": inferior, "superior": superior,
                             "ocorrencias": int(mascara.sum()), "denominador": numero_linhas})
    if coluna == "duration":
        outliers_duracao = mascara
    else:
        outliers_rank = mascara
```

```
display(pd.DataFrame(limites_outliers))
display(df_bruto.loc[outliers_duracao, ["id", "title", "duration", "chart_nome_genero"]])
integridade = pd.Series(False, index=df_bruto.index)
for origem, detalhe in [("id", "detalhe_faixa_id"), ("album_id", "detalhe_album_id"),
                        ("artist_id", "detalhe_artista_id")]:
    integridade |= df_bruto[origem].isna() | df_bruto[detalhe].isna() | df_bruto[origem].ne(df_bruto[detalhe])
divergencia_duracao = df_bruto["duration"].ne(df_bruto["detalhe_faixa_duration"])
divergencia_rank = df_bruto["rank"].ne(df_bruto["detalhe_faixa_rank"])
```

	atributo	inferior	superior	ocorrencias	denominador
0	duration	66.50	366.50	143	2800
1	rank	-445721.75	1316536.25	0	2800

	id	title	duration	chart_nome_genero
139	374283061	Purple Rain (2015 Paisley Park Remaster)	524	Pop
202	131391760	Cinderella (feat. Ty Dolla $ign)	480	Rap/Hip Hop
213	921331222	A Nightmare On My Street	368	Rap/Hip Hop
215	1580929572	The Humpty Dance	391	Rap/Hip Hop
230	6617606	C'mon N' Ride It (The Train)	451	Rap/Hip Hop
...	...	...	...	...
2646	29673331	Thunder & Gentle Rain Soundscape	599	Kids
2694	2023467557	PAW Patrol Opening Theme	41	Kids
2697	1678115237	Concerto in C Major for Flute, Harp and Orches...	519	Kids
2723	686087352	Merecumbe	381	Latin Music
2743	3171003001	BAILE INoLVIDABLE	367	Latin Music

143 rows × 4 columns

```
# Diagnóstico de qualidade Q1 a Q21
campos_essenciais = ["id", "chart_id_genero", "chart_nome_genero", "title", "duration", "rank",
                     "position", "artist_id", "artist_name", "album_id", "detalhe_faixa_release_date",
                     "detalhe_artista_nb_fan"]
verificacoes = [
    ("Q1", "Ausência em pelo menos um campo essencial às P1-P4 ou RA2",
mascara_ausencias[campos_essenciais].any(axis=1), "Ausências nulas e textos vazios"),
    ("Q2", "Ausência de preview (nulo ou texto vazio)", mascara_ausencias["preview"], "Ausências nulas e textos
vazios"),
    ("Q3", "Ausência de title_version (nulo ou texto vazio)", mascara_ausencias["title_version"], "Ausências nulas e
textos vazios"),
    ("Q4", "Ocorrências excedentes por id, após a primeira", duplicadas_id, "Duplicidade e limite da chave"),
    ("Q5", "Ocorrências excedentes pelo par chart_id_genero e id", duplicadas_chart, "Duplicidade e limite da
chave"),
    ("Q6", "Linhas inteiras repetidas, após a primeira", duplicadas_inteiras, "Duplicidade e limite da chave"),
    ("Q7", "Tipo divergente de numérico inteiro/real ou booleano esperado", tipos_invalidos, "Estatísticas
descritivas e domínios numéricos"),
    ("Q8", "Numéricos não finitos/ausentes ou fora dos domínios descritos", invalidos_numericos, "Estatísticas
descritivas e domínios numéricos"),
    ("Q9", "bpm igual a zero (sinal de dado não informado)", bpm_zero, "Estatísticas descritivas e domínios
numéricos"),
    ("Q10", "gain igual a zero (a avaliar, não erro comprovado)", gain_zero, "Estatísticas descritivas e domínios
numéricos"),
    ("Q11", "Data fora de AAAA-MM-DD, inválida ou fora de 1900 até a coleta", datas_invalidas, "Datas, formatos e
categorias"),
    ("Q12", "Espaços nas pontas de título, artista ou gênero", espacos, "Datas, formatos e categorias"),
    ("Q13", "Mais de um nome para um id de artista", variacoes_artista, "Datas, formatos e categorias"),
    ("Q14", "Gênero com mais de um nome ou nome normalizado com mais de um id", categorias_inconsistentes, "Datas,
formatos e categorias"),
    ("Q15", "Chart geral id 0: não representa um gênero específico", chart_geral, "Datas, formatos e categorias"),
    ("Q16", "Gênero do álbum genérico (id menor ou igual a zero)", genero_album_generico, "Datas, formatos e
categorias"),
    ("Q17", "Duração fora de Q1 − 1,5 IQR a Q3 + 1,5 IQR", outliers_duracao, "Possíveis outliers e integridade do
enriquecimento"),
    ("Q18", "Rank fora de Q1 − 1,5 IQR a Q3 + 1,5 IQR", outliers_rank, "Possíveis outliers e integridade do
enriquecimento"),
```

```
    ("Q19", "Id ausente ou divergente na junção de faixa/álbum/artista", integridade, "Possíveis outliers e
integridade do enriquecimento"),
    ("Q20", "Duração do chart diferente da duração em /track", divergencia_duracao, "Possíveis outliers e
integridade do enriquecimento"),
    ("Q21", "Rank do chart diferente do rank em /track", divergencia_rank, "Possíveis outliers e integridade do
enriquecimento"),
]
# Somar uma coluna de True/False conta quantas linhas apresentaram o problema.
resultados = []
for identificador, regra, mascara, celula in verificacoes:
    quantidade = int(mascara.sum())
    resultados.append({
        "ID": identificador,
        "regra": regra,
        "quantidade": quantidade,
        "denominador": numero_linhas,
        "percentual": 100 * quantidade / numero_linhas,
        "celula": celula,
    })

diagnostico = pd.DataFrame(resultados)
display(diagnostico)
print("As proporções usam ocorrências nos charts e podem se sobrepor; não devem ser somadas.")
```

	ID	regra	quantidade	denominador	percentual	celula
0	Q1	Ausência em pelo menos um campo essencial às P...	0	2800	0.000000	Ausências nulas e textos vazios
1	Q2	Ausência de preview (nulo ou texto vazio)	1	2800	0.035714	Ausências nulas e textos vazios
2	Q3	Ausência de title_version (nulo ou texto vazio)	2533	2800	90.464286	Ausências nulas e textos vazios
3	Q4	Ocorrências excedentes por id, após a primeira	219	2800	7.821429	Duplicidade e limite da chave
4	Q5	Ocorrências excedentes pelo par chart_id_gener...	0	2800	0.000000	Duplicidade e limite da chave
5	Q6	Linhas inteiras repetidas, após a primeira	0	2800	0.000000	Duplicidade e limite da chave
6	Q7	Tipo divergente de numérico inteiro/real ou bo...	0	2800	0.000000	Estatísticas descritivas e domínios numéricos
7	Q8	Numéricos não finitos/ausentes ou fora dos dom...	0	2800	0.000000	Estatísticas descritivas e domínios numéricos
8	Q9	bpm igual a zero (sinal de dado não informado)	1890	2800	67.500000	Estatísticas descritivas e domínios numéricos
9	Q10	gain igual a zero (a avaliar, não erro comprov...	27	2800	0.964286	Estatísticas descritivas e domínios numéricos
10	Q11	Data fora de AAAA-MM-DD, inválida ou fora de 1...	1	2800	0.035714	Datas, formatos e categorias
11	Q12	Espaços nas pontas de título, artista ou gênero	1	2800	0.035714	Datas, formatos e categorias
12	Q13	Mais de um nome para um id de artista	0	2800	0.000000	Datas, formatos e categorias
13	Q14	Gênero com mais de um nome ou nome normalizado...	0	2800	0.000000	Datas, formatos e categorias
14	Q15	Chart geral id 0: não representa um gênero esp...	100	2800	3.571429	Datas, formatos e categorias
15	Q16	Gênero do álbum genérico (id menor ou igual a ...	11	2800	0.392857	Datas, formatos e categorias
16	Q17	Duração fora de Q1 − 1,5 IQR a Q3 + 1,5 IQR	143	2800	5.107143	Possíveis outliers e integridade do enriquecim...

	ID	regra	quantidade	denominador	percentual	celula
17	Q18	Rank fora de Q1 − 1,5 IQR a Q3 + 1,5 IQR	0	2800	0.000000	Possíveis outliers e integridade do enriquecim...
18	Q19	Id ausente ou divergente na junção de faixa/ál...	0	2800	0.000000	Possíveis outliers e integridade do enriquecim...
19	Q20	Duração do chart diferente da duração em /track	0	2800	0.000000	Possíveis outliers e integridade do enriquecim...
20	Q21	Rank do chart diferente do rank em /track	0	2800	0.000000	Possíveis outliers e integridade do enriquecim...

```
As proporções usam ocorrências nos charts e podem se sobrepor; não devem ser somadas.
```

Resposta do grupo:

Uma linha representa uma ocorrência de faixa em um chart no retrato da coleta. A chave candidata é o par `chart_id_genero` e `id`, dentro desse retrato. `id` identifica a faixa, mas não é único entre charts. As verificações acima contam ocorrências, não faixas distintas, salvo indicação explícita.

No retrato de 16/10/2026, são 2.800 ocorrências, 102 colunas e 2.581 faixas. Há 219/2.800 repetições excedentes por `id` (7,82%), mas nenhuma pela chave chart-faixa. BPM é zero em 1.890/2.800 ocorrências (67,50%); `title_version` está ausente em 2.533/2.800 (90,46%). Uma ocorrência tem lançamento posterior à coleta, e 143/2.800 (5,11%) têm duração fora dos limites IQR. Evidências: células “Visão geral e tipos observados” e “Diagnóstico de qualidade Q1 a Q21”. A repetição por `id` exige preservar o chart de origem na preparação, pois ele define os grupos das perguntas P1 a P4. O chart geral deve ser identificado separadamente dos gêneros. BPM zero e versões sem texto precisam de interpretação; valores extremos de duração são candidatos à inspeção, sem exclusão automática. O diagnóstico completo e as prioridades estão no documento “Compreensão e qualidade”, com as mesmas contagens do quadro Q1 a Q21.

4. Limpeza e preparação dos dados

Realize a limpeza necessária ao projeto. Verifique valores ausentes, duplicados e inconsistências e trate os problemas encontrados, quando necessário.

```
# Cópia de trabalho e referência do bruto
import numpy as np
import pandas as pd
from IPython.display import display

referencia_bruta_preparacao = df_bruto.copy(deep=True)
df_preparado = df_bruto.copy(deep=True)
total_antes_preparacao = len(df_bruto)
assert total_antes_preparacao > 0, "Execute a ingestão antes de preparar os dados."
print(f"Entrada: {total_antes_preparacao} ocorrências × {df_bruto.shape[1]} atributos.")
```

```
Entrada: 2800 ocorrências × 102 atributos.
```

```
# Preservação do vínculo entre faixa e chart
# D1 (Q4-Q6): a faixa pode se repetir entre charts, mas a chave composta é única.
chave_bruta = ["chart_id_genero", "id"]
repeticoes_id_antes = int(df_bruto.duplicated("id").sum())
duplicatas_chave_antes = int(df_bruto.duplicated(chave_bruta).sum())
assert df_bruto[chave_bruta].notna().all().all(), "Chave de origem incompleta."
assert duplicatas_chave_antes == 0, "Revise o diagnóstico: há pares chart-faixa repetidos."
pd.testing.assert_frame_equal(df_preparado[chave_bruta], df_bruto[chave_bruta])
print(f"D1: {repeticoes_id_antes}/{total_antes_preparacao} excedentes por id mantidos; "
      f"{duplicatas_chave_antes}/{total_antes_preparacao} duplicatas chart-faixa.")
```

```
D1: 219/2800 excedentes por id mantidos; 0/2800 duplicatas chart-faixa.
```

```
# Padronização dos campos textuais
# D2 (Q12): remover somente espaços nas pontas, preservando acentos e a escrita.
colunas_textuais_preparacao = ["title", "artist_name", "chart_nome_genero"]
espacos_antes_preparacao = pd.Series(False, index=df_bruto.index)
alteracoes_textuais_preparacao = []
for coluna in colunas_textuais_preparacao:
```

```
    antes = df_preparado[coluna].astype("string")
    depois = antes.str.strip()
    alteradas = antes.ne(depois).fillna(False)
    espacos_antes_preparacao |= alteradas
    for indice in df_preparado.index[alteradas]:
        alteracoes_textuais_preparacao.append({
            "id_faixa": int(df_preparado.at[indice, "id"]),
            "campo": coluna, "antes": repr(antes.at[indice]),
            "depois": repr(depois.at[indice]),
        })
    df_preparado[coluna] = depois
    assert depois.eq(depois.str.strip()).fillna(True).all()
print(f"D2: {int(espacos_antes_preparacao.sum())}/{total_antes_preparacao} "
      "ocorrências corrigidas; nenhuma linha excluída.")
display(pd.DataFrame(alteracoes_textuais_preparacao).head(10))
```

```
D2: 1/2800 ocorrências corrigidas; nenhuma linha excluída.
```

	id_faixa	campo	antes	depois
0	70057719	artist_name	'Sona Mohapatra\xa0'	'Sona Mohapatra'

```
# Conversão e validação temporal
# D3 (Q11): conservar o lançamento e identificar datas posteriores à coleta.
texto_lancamento_preparacao = df_preparado["detalhe_faixa_release_date"].astype("string")
assert texto_lancamento_preparacao.str.fullmatch(r"\d{4}-\d{2}-\d{2}").fillna(False).all()
datas_lancamento_preparacao = pd.to_datetime(
    texto_lancamento_preparacao, format="%Y-%m-%d", errors="raise"
)
assert datas_lancamento_preparacao.notna().all()
assert datas_lancamento_preparacao.ge(pd.Timestamp("1900-01-01")).all()
assert datas_lancamento_preparacao.dt.strftime("%Y-%m-%d").eq(
    texto_lancamento_preparacao
).all()
data_retrato_preparacao = pd.Timestamp(metadados["inicio_utc"])
if data_retrato_preparacao.tzinfo is not None:
    data_retrato_preparacao = data_retrato_preparacao.tz_convert("UTC").tz_localize(None)
data_retrato_preparacao = data_retrato_preparacao.normalize()
df_preparado["detalhe_faixa_release_date"] = datas_lancamento_preparacao
df_preparado["data_coleta"] = data_retrato_preparacao
df_preparado["lancamento_posterior_coleta"] = (
    datas_lancamento_preparacao > data_retrato_preparacao
)
print(f"D3: {int(df_preparado['lancamento_posterior_coleta'].sum())}/"
      f"{total_antes_preparacao} lançamentos posteriores à coleta, preservados.")
display(df_preparado.loc[
    df_preparado["lancamento_posterior_coleta"],
    ["id", "title", "detalhe_faixa_release_date", "data_coleta"],
].head(10))
```

```
D3: 1/2800 lançamentos posteriores à coleta, preservados.
```

	id	title	detalhe_faixa_release_date	data_coleta
1755	4346251442	Dirty Bird	2026-10-28	2026-10-16

```
# Identificação do chart de origem
# D4 (Q14-Q16): o gênero do álbum não substitui o chart de origem.
df_preparado["tipo_chart"] = df_preparado["chart_id_genero"].map(
    lambda identificador: "geral" if identificador == 0 else "genero"
)
charts_gerais_preparacao = df_preparado["chart_id_genero"].eq(0)
assert df_preparado["tipo_chart"].eq("geral").equals(charts_gerais_preparacao)
assert df_preparado.groupby("chart_id_genero")["chart_nome_genero"].nunique().eq(1).all()
print(f"D4: {int(charts_gerais_preparacao.sum())}/{total_antes_preparacao} "
      "ocorrências identificadas como chart geral, sem exclusão.")
```

```
D4: 100/2800 ocorrências identificadas como chart geral, sem exclusão.
```

```
# Sinalização dos extremos de duração
# D7 (Q17-Q18): reproduzir a regra da seção 3, sem alterar duração ou rank.
quartis_duracao_preparacao = df_bruto["duration"].quantile([0.25, 0.75])
```

```
amplitude_duracao_preparacao = quartis_duracao_preparacao.iloc[1] - (
    quartis_duracao_preparacao.iloc[0]
)
limite_inferior_duracao = quartis_duracao_preparacao.iloc[0] - (
    1.5 * amplitude_duracao_preparacao
)
limite_superior_duracao = quartis_duracao_preparacao.iloc[1] + (
    1.5 * amplitude_duracao_preparacao
)
df_preparado["duracao_fora_limites_iqr"] = (
    df_preparado["duration"].lt(limite_inferior_duracao)
    | df_preparado["duration"].gt(limite_superior_duracao)
)
pd.testing.assert_series_equal(df_preparado["duration"], df_bruto["duration"])
pd.testing.assert_series_equal(df_preparado["rank"], df_bruto["rank"])
print(f"D7: limites {limite_inferior_duracao:g} a {limite_superior_duracao:g} s; "
      f"{int(df_preparado['duracao_fora_limites_iqr'].sum())}/"
      f"{total_antes_preparacao} ocorrências sinalizadas e mantidas.")
```

```
D7: limites 66.5 a 366.5 s; 143/2800 ocorrências sinalizadas e mantidas.
```

```
# Registro das decisões de preparação
decisoes_preparacao = pd.DataFrame([
    ("D1", "Q4-Q6", "Preservar o vínculo chart-faixa", "Nenhuma linha excluída"),
    ("D2", "Q12", "Remover espaços nas pontas", "Preservar a escrita dos nomes"),
    ("D3", "Q11", "Converter e sinalizar datas", "Não imputar lançamento"),
    ("D4", "Q14-Q16", "Identificar o tipo de chart", "Preservar a origem"),
    ("D5", "Q2, Q3, Q9, Q10", "Selecionar atributos na seção 5", "Não excluir faixas"),
    ("D6", "Q7, Q8", "Padronizar nomes e tipos na seção 5", "Não alterar números válidos"),
    ("D7", "Q17, Q18", "Sinalizar extremos", "Não cortar ou substituir valores"),
    ("D8", "Q1, Q13, Q19-Q21", "Revalidar consistência na seção 5", "Manter dados aprovados"),
], columns=["decisao", "diagnostico", "acao", "justificativa"])
display(decisoes_preparacao)
pd.testing.assert_frame_equal(df_bruto, referencia_bruta_preparacao)
assert len(df_preparado) == total_antes_preparacao
```

	decisao	diagnostico	acao	justificativa
0	D1	Q4–Q6	Preservar o vínculo chart-faixa	Nenhuma linha excluída
1	D2	Q12	Remover espaços nas pontas	Preservar a escrita dos nomes
2	D3	Q11	Converter e sinalizar datas	Não imputar lançamento
3	D4	Q14–Q16	Identificar o tipo de chart	Preservar a origem
4	D5	Q2, Q3, Q9, Q10	Selecionar atributos na seção 5	Não excluir faixas
5	D6	Q7, Q8	Padronizar nomes e tipos na seção 5	Não alterar números válidos
6	D7	Q17, Q18	Sinalizar extremos	Não cortar ou substituir valores
7	D8	Q1, Q13, Q19–Q21	Revalidar consistência na seção 5	Manter dados aprovados

Resposta do grupo:

As decisões D1–D8 respondem às verificações Q1–Q21. A preparação preserva a participação de cada faixa nos charts, corrige espaços e sinaliza situações que exigem cuidado, sem excluir automaticamente dados por critérios estatísticos.

Preservamos as 2.800 ocorrências e o vínculo faixa-chart (D1), com 219/2.800 excedentes por id e nenhuma duplicata pela chave composta. Corrigimos espaços nas pontas em 1/2.800 ocorrências (D2), convertemos o lançamento e sinalizamos 1/2.800 datas posteriores à coleta (D3). Identificamos separadamente as 100/2.800 ocorrências do chart geral (D4). As 143/2.800 durações fora dos limites IQR foram sinalizadas, sem exclusão nem substituição (D7).

Evidências: células “Preservação do vínculo entre faixa e chart”, “Padronização dos campos textuais”, “Conversão e validação temporal”, “Identificação do chart de origem” e “Sinalização dos extremos de duração”. A seção 5 conclui D5, D6 e D8 com seleção, padronização, validação e gravação. O bruto permanece intacto.

5. Transformação dos dados

Realize as transformações necessárias à análise, como criação de colunas, filtros, agrupamentos, conversões ou junções, quando aplicáveis.

```
# Seleção e organização dos atributos
# D5: doze atributos do bruto e quatro campos de contexto ou qualidade.
nomes_colunas_preparadas = {
    "id": "id_faixa", "title": "titulo", "chart_id_genero": "id_chart",
    "chart_nome_genero": "genero", "tipo_chart": "tipo_chart",
    "position": "posicao_chart", "artist_id": "id_artista", "artist_name": "artista",
    "album_id": "id_album", "duration": "duracao_s", "rank": "rank",
    "detalhe_artista_nb_fan": "numero_fas",
    "detalhe_faixa_release_date": "data_lancamento", "data_coleta": "data_coleta",
    "lancamento_posterior_coleta": "lancamento_posterior_coleta",
    "duracao_fora_limites_iqr": "duracao_fora_limites_iqr",
}
df_preparado = df_preparado.loc[:, list(nomes_colunas_preparadas)].rename(
    columns=nomes_colunas_preparadas
)
assert df_preparado.columns.tolist() == list(nomes_colunas_preparadas.values())
assert len(df_preparado) == total_antes_preparacao
print(f"D5: {df_bruto.shape[1]} atributos de origem → "
      f"{df_preparado.shape[1]} atributos finais; {len(df_preparado)} linhas preservadas.")
```

```
D5: 102 atributos de origem → 16 atributos finais; 2800 linhas preservadas.
```

```
# Padronização dos nomes e tipos
# D6: rank mantém o nome já esperado pelo gerador de eventos da seção 9.
colunas_inteiras_preparadas = [
    "id_faixa", "id_chart", "posicao_chart", "id_artista", "id_album",
    "duracao_s", "rank", "numero_fas",
]
colunas_textuais_preparadas = ["titulo", "genero", "tipo_chart", "artista"]
colunas_datas_preparadas = ["data_lancamento", "data_coleta"]
colunas_booleanas_preparadas = [
    "lancamento_posterior_coleta", "duracao_fora_limites_iqr",
]
for coluna in colunas_inteiras_preparadas:
    valores = pd.to_numeric(df_preparado[coluna], errors="raise")
    assert valores.notna().all() and np.isfinite(valores).all(), coluna
    assert valores.mod(1).eq(0).all(), f"Inteiro fracionário em {coluna}."
    df_preparado[coluna] = valores.astype("int64")
for coluna in colunas_textuais_preparadas:
    df_preparado[coluna] = df_preparado[coluna].astype("string")
for coluna in colunas_datas_preparadas:
    df_preparado[coluna] = pd.to_datetime(
        df_preparado[coluna], errors="raise"
    ).astype("datetime64[ns]")
for coluna in colunas_booleanas_preparadas:
    assert pd.api.types.is_bool_dtype(df_preparado[coluna]), coluna
display(df_preparado.dtypes.astype(str).rename("tipo").to_frame())
```

	tipo
id_faixa	int64
titulo	string
id_chart	int64
genero	string
tipo_chart	string
posicao_chart	int64
id_artista	int64
artista	string
id_album	int64
duracao_s	int64
rank	int64
numero_fas	int64

	tipo
data_lancamento	datetime64[ns]
data_coleta	datetime64[ns]
lancamento_posterior_coleta	bool
duracao_fora_limites_iqr	bool

```
# Verificações finais do conjunto preparado
# D8: falhas são expostas; não há preenchimento automático nem remoção de linhas.
assert df_preparado.notna().all().all(), "O conjunto selecionado tem valores ausentes."
chave_preparada = ["data_coleta", "id_chart", "id_faixa"]
assert not df_preparado.duplicated(chave_preparada).any()
for coluna in ["id_faixa", "id_artista", "id_album", "duracao_s", "posicao_chart"]:
    assert df_preparado[coluna].gt(0).all(), coluna
for coluna in ["id_chart", "rank", "numero_fas"]:
    assert df_preparado[coluna].ge(0).all(), coluna
for coluna in colunas_textuais_preparadas:
    assert df_preparado[coluna].str.strip().ne("").all(), coluna
    assert df_preparado[coluna].eq(df_preparado[coluna].str.strip()).all(), coluna
assert df_preparado["tipo_chart"].isin(["geral", "genero"]).all()
assert df_preparado["tipo_chart"].eq("geral").eq(df_preparado["id_chart"].eq(0)).all()
assert df_preparado.groupby("id_chart")["genero"].nunique().eq(1).all()
assert df_preparado.groupby("id_artista")["artista"].nunique().eq(1).all()
assert df_preparado["lancamento_posterior_coleta"].equals(
    df_preparado["data_lancamento"].gt(df_preparado["data_coleta"])
)
assert df_preparado["duracao_fora_limites_iqr"].equals(
    df_preparado["duracao_s"].lt(limite_inferior_duracao)
    | df_preparado["duracao_s"].gt(limite_superior_duracao)
)
# A correspondência linha a linha garante que a seleção não perdeu a origem.
for origem, destino in nomes_colunas_preparadas.items():
    if destino in colunas_inteiras_preparadas:
        pd.testing.assert_series_equal(
            df_preparado[destino], df_bruto[origem].astype("int64"), check_names=False
        )
for origem, detalhe in [
    ("id", "detalhe_faixa_id"), ("album_id", "detalhe_album_id"),
    ("artist_id", "detalhe_artista_id"),
]:
    assert df_bruto[origem].eq(df_bruto[detalhe]).all(), detalhe
assert df_preparado["duracao_s"].eq(df_bruto["detalhe_faixa_duration"]).all()
assert df_preparado["rank"].eq(df_bruto["detalhe_faixa_rank"]).all()
assert df_preparado["data_lancamento"].dt.strftime("%Y-%m-%d").eq(
    df_bruto["detalhe_faixa_release_date"].astype("string")
).all()
assert df_preparado["data_coleta"].eq(data_retrato_preparacao).all()
pd.testing.assert_frame_equal(df_bruto, referencia_bruta_preparacao)
print(f"Validações aprovadas em {len(df_preparado)} ocorrências: "
      "tipos, domínios, ausências, chave, datas, sinalizações e integridade.")
```

```
Validações aprovadas em 2800 ocorrências: tipos, domínios, ausências, chave, datas, sinalizações e integridade.
```

```
# Comparação antes e depois da preparação
espacos_depois_preparacao = pd.Series(False, index=df_preparado.index)
for coluna in colunas_textuais_preparadas:
    espacos_depois_preparacao |= df_preparado[coluna].ne(
        df_preparado[coluna].str.strip()
    )
comparacao_preparacao = pd.DataFrame([
    ("Registros", total_antes_preparacao, len(df_preparado)),
    ("Atributos", df_bruto.shape[1], df_preparado.shape[1]),
    ("Ocorrências com espaços nas pontas", int(espacos_antes_preparacao.sum()),
     int(espacos_depois_preparacao.sum())),
    ("Duplicatas chart-faixa", duplicatas_chave_antes,
     int(df_preparado.duplicated(chave_preparada).sum())),
    ("Excedentes por id da faixa", repeticoes_id_antes,
     int(df_preparado.duplicated("id_faixa").sum())),
    ("Ocorrências do chart geral", int(charts_gerais_preparacao.sum()),
     int(df_preparado["tipo_chart"].eq("geral").sum())),
    ("Lançamentos posteriores à coleta",
```

```
    int(datas_lancamento_preparacao.gt(data_retrato_preparacao).sum()),
    int(df_preparado["lancamento_posterior_coleta"].sum())),
   ("Durações fora dos limites IQR",
    int((df_bruto["duration"].lt(limite_inferior_duracao)
         | df_bruto["duration"].gt(limite_superior_duracao)).sum()),
    int(df_preparado["duracao_fora_limites_iqr"].sum())),
], columns=["medida", "antes", "depois"])
display(comparacao_preparacao)
print(f"Denominador das medidas por ocorrência: {total_antes_preparacao} antes "
      f"e {len(df_preparado)} depois; as medidas podem se sobrepor.")
```

	medida	antes	depois
0	Registros	2800	2800
1	Atributos	102	16
2	Ocorrências com espaços nas pontas	1	0
3	Duplicatas chart-faixa	0	0
4	Excedentes por id da faixa	219	219
5	Ocorrências do chart geral	100	100
6	Lançamentos posteriores à coleta	1	1
7	Durações fora dos limites IQR	143	143

```
Denominador das medidas por ocorrência: 2800 antes e 2800 depois; as medidas podem se sobrepor.
```

```
# Gravação e releitura do conjunto preparado
arquivo_preparado = PASTA_PREPARADOS / "faixas_preparadas.csv"
# Fim de linha "\n" fixo: o arquivo sai igual no Windows, no Linux e no Colab
df_preparado.to_csv(arquivo_preparado, index=False, encoding="utf-8", date_format="%Y-%m-%d",
                    lineterminator="\n")
tipos_releitura_preparacao = {
    **{coluna: "int64" for coluna in colunas_inteiras_preparadas},
    **{coluna: "string" for coluna in colunas_textuais_preparadas},
    **{coluna: "bool" for coluna in colunas_booleanas_preparadas},
}
releitura_preparacao = pd.read_csv(
    arquivo_preparado, encoding="utf-8", dtype=tipos_releitura_preparacao,
    parse_dates=colunas_datas_preparadas,
)
pd.testing.assert_frame_equal(df_preparado, releitura_preparacao)
tamanho_preparado = f"{arquivo_preparado.stat().st_size:,}".replace(",", ".")
print(f"Arquivo: {arquivo_preparado.relative_to(RAIZ)} · UTF-8, separador vírgula, "
      f"{tamanho_preparado} bytes.")
print(f"Releitura validada: {len(releitura_preparacao)} linhas × "
      f"{releitura_preparacao.shape[1]} colunas, sem perda de valores.")
display(df_preparado.head(5))
```

```
Arquivo: dados/preparados/faixas_preparadas.csv · UTF-8, separador vírgula, 367.932 bytes.
Releitura validada: 2800 linhas × 16 colunas, sem perda de valores.
```

	id_faixa	titulo	id_chart	genero	tipo_chart	posicao_chart	id_artista	artista	id_album
0	3818963601	Dracula (with JENNIE)	0	All	geral	1	134790	Tame Impala	910510411
1	3895241341	Boston	0	All	geral	2	181157207	STELLA LEFTY	937796461
2	3834003271	Be Her	0	All	geral	3	14867123	Ella Langley	915466851
3	3602074142	Choosin' Texas	0	All	geral	4	14867123	Ella Langley	837881302
4	4167204822	Been By Now	0	All	geral	5	7188840	Morgan Wallen	1034275572

	duracao_s	rank	numero_fas	data_lancamento	data_coleta	lancamento_posterior_coleta
0	209	982905	1152208	2026-02-06	2026-10-16	False

	duracao_s	rank	numero_fas	data_lancamento	data_coleta	lancamento_posterior_coleta
1	170	873262	3583	2026-03-27	2026-10-16	False
2	217	805867	33537	2026-02-13	2026-10-16	False
3	232	978085	33537	2025-10-17	2026-10-16	False
4	213	768651	304123	2026-07-24	2026-10-16	False

	duracao_fora_limites_iqr
0	False
1	False
2	False
3	False
4	False

Resposta do grupo:

Selecionamos os atributos, padronizamos nomes e tipos e gravamos o conjunto preparado. A unidade continua sendo uma ocorrência de faixa por chart e data de coleta. As perguntas analíticas serão respondidas posteriormente.

O conjunto preparado está em `dados/preparados/faixas_preparadas.csv`, com 2.800 ocorrências e 16 colunas: 12 atributos selecionados do bruto e quatro campos de contexto ou qualidade. Nenhuma linha foi excluída. Os espaços nas pontas passaram de 1/2.800 para 0/2.800 ocorrências. A chave data-chart-faixa permaneceu sem duplicatas; as 219/2.800 repetições por id foram preservadas. Evidências: células “Comparação antes e depois da preparação” e “Gravação e releitura do conjunto preparado”.

As 100/2.800 ocorrências do chart geral estão identificadas em `tipo_chart`. A data futura (1/2.800) e os extremos de duração (143/2.800) foram mantidos e sinalizados, sem confirmação de suas causas. O CSV não inclui BPM, ganho, prévia ou versão complementar; esses dados continuam no bruto. O gerador do RA2 precisa filtrar o chart geral ao usar o preparado, mantendo somente `tipo_chart == "genero"` para os eventos por gênero.

7. Considerações do RA1

Registre brevemente:

- O que o grupo descobriu sobre os dados.
- Quais dificuldades ou limitações encontrou.
- Como os dados preparados poderão ser utilizados nas próximas etapas.

Resposta do grupo:

O que descobrimos sobre os dados. O retrato de 16/10/2026 tem 2.800 ocorrências de 2.581 faixas em 28 charts, o geral e 27 gêneros. Nos campos que as perguntas usam, a qualidade de origem é boa: nenhuma ausência nos campos essenciais, nenhum tipo divergente e a mesma duração e o mesmo `rank` no chart e no detalhe da faixa nas 2.800 ocorrências (Q1, Q7, Q20 e Q21). Os problemas estão em campos fora das perguntas: `bpm` zerado em 1.890/2.800 ocorrências (67,50%) e `title_version` vazio em 2.533/2.800 (90,46%). Uma faixa pode estar em mais de um chart (219/2.800 ocorrências excedentes por `id`, 7,82%), por isso cada linha do conjunto preparado é uma faixa num chart. Evidência: seção 3, célula "Diagnóstico de qualidade Q1 a Q21".

Dificuldades e limitações. O chart muda todo dia e varia com o país: os números valem para um único retrato, coletado com país aparente US (seção 2). A API não informa reproduções, só o `rank`, um índice calculado pela Deezer. Uma data de lançamento posterior à coleta (1/2.800) e 143/2.800 durações fora dos limites IQR (5,11%) foram mantidas e sinalizadas, sem confirmar a causa. As 100/2.800 ocorrências do chart geral não representam um gênero. `bpm`, ganho, prévia e versão ficaram fora do conjunto preparado e continuam só no retrato bruto. Evidências: seção 4, células "Conversão e validação temporal", "Identificação do chart de origem" e "Sinalização dos extremos de duração".

Uso nas próximas etapas. O conjunto `dados/preparados/faixas_preparadas.csv` tem 2.800 linhas e 16 colunas, gravado e relido sem perda (seção 5, célula "Gravação e releitura do conjunto preparado"). No RA2, as 2.700 ocorrências dos charts de gênero alimentam os eventos de reprodução simulados (seção 9, célula "Faixas que alimentam os eventos"). No RA3, `duracao_s`, `data_lancamento`, `rank`, `numero_fas`, `id_artista`, `posicao_chart` e `genero` atendem às perguntas P1 a P4;

`tipo_chart` separa o chart geral, e `lancamento_posterior_coleta` e `duracao_fora_limites_iqr` permitem decidir, na análise, como tratar a data futura e os extremos.

RA2 — Streaming Data Processing and Time Windows

Utilize os dados e o contexto do projeto para demonstrar o processamento em streaming e a aplicação de janelas temporais. Escolha um dos cenários:

- **Cenário A — Dados estáticos:** simule a chegada de novos registros utilizando dados artificiais coerentes com o contexto do projeto.
- **Cenário B — Dados em streaming:** utilize sua própria fonte de dados contínuos, sem necessidade de simulação.

8. Objetivo da análise em streaming

Responda brevemente:

- O que o grupo deseja monitorar ou analisar?
- Qual informação espera obter com o processamento em streaming?

Resposta do grupo:

No RA1, o grupo compara entre gêneros o perfil das faixas que estão no topo dos charts da Deezer. No RA2, o grupo quer **monitorar as reproduções dessas faixas por gênero ao longo do tempo**. Como a API da Deezer não oferece um fluxo de reproduções, usamos o cenário A: eventos de reprodução simulados, sorteados entre as faixas e os gêneros do conjunto preparado do RA1.

Com o processamento em streaming, esperamos saber, a cada janela de tempo, **quantas reproduções cada gênero acumula** e **qual gênero concentra mais reproduções naquele intervalo**, e ver esses números mudarem conforme novos lotes de eventos chegam. O tipo e a duração da janela estão na seção 10.

9. Fonte de dados e processamento

- Informe o cenário escolhido: dados reais em streaming ou simulação.
- Explique brevemente como os novos registros chegam.
- Implemente o processamento em tempo real.
- Demonstre o recebimento de novos registros.

Resposta do grupo:

Usamos o cenário A, de simulação, porque a API da Deezer não oferece um fluxo de reproduções em tempo real. Cada registro novo é uma reprodução de faixa, com `id_evento`, `id_faixa`, `genero`, `artista`, `duracao_ouvida_s` e `instante`. A função `gerar_eventos` sorteia faixas e gêneros reais do conjunto do RA1, com chance proporcional ao `rank` da Deezer, semente 42 e primeiro instante em 21/10/2026 às 10:00, e espaça os eventos de 5 a 30 segundos.

Os registros chegam em lotes: `publicar_lote` grava cada lote como um arquivo JSON, com um evento por linha, e só então o move para `dados/streaming/entrada/`, a pasta que o Spark monitora com `spark.readStream` e esquema explícito. A consulta de recebimento conta os eventos que chegaram: antes do 1º lote a tabela está vazia e, depois dele, mostra 30 eventos, de 10:00:28 a 10:09:05, de 19 gêneros. A janela temporal é aplicada na seção 10, e os lotes seguintes chegam na seção 11.

```
%%capture
# Instalação do PySpark (só no Colab)
if NO_COLAB:
    %pip install -q "pyspark==4.0.3"
```

```
# Sessão do Spark
from pyspark.sql import SparkSession
from pyspark.sql import functions as F
from pyspark.sql.types import IntegerType, LongType, StringType, StructField, StructType, TimestampType

import os

# Os avisos de inicialização do Java e do Spark (nome da máquina, perfil de log) vão para um arquivo,
```

```
# e não para a saída da célula; se a sessão não abrir, o fim desse arquivo é mostrado com o erro.
LOG_SPARK = PASTA_STREAMING / "spark.log"
saida_erro = os.dup(2)
with open(LOG_SPARK, "w") as arquivo_log:
    os.dup2(arquivo_log.fileno(), 2)
    try:
        spark = (
            SparkSession.builder.master("local[2]")
            .appName("data-analytics — RA2")
            .config("spark.sql.session.timeZone", "America/Sao_Paulo")
            .config("spark.sql.shuffle.partitions", "2")
            .getOrCreate()
        )
    except Exception:
        os.dup2(saida_erro, 2)
        print(LOG_SPARK.read_text()[-2000:])
        raise
    finally:
        os.dup2(saida_erro, 2)
        os.close(saida_erro)
# Aplica o fuso também se já houver uma sessão aberta (reexecução da seção)
spark.conf.set("spark.sql.session.timeZone", "America/Sao_Paulo")
spark.sparkContext.setLogLevel("ERROR")

# Consultas que sobraram de uma execução anterior seguram arquivos das pastas abaixo
for consulta_antiga in spark.streams.active:
    consulta_antiga.stop()

print(f"Spark {spark.version} · fuso {spark.conf.get('spark.sql.session.timeZone')}")
```

```
Spark 4.0.3 · fuso America/Sao_Paulo
```

```
# Pastas do streaming
import json
import shutil
from datetime import datetime, timedelta
from uuid import uuid4

import numpy as np

PASTA_ENTRADA = PASTA_STREAMING / "entrada"          # monitorada pelo Spark
PASTA_PUBLICACAO = PASTA_STREAMING / "publicacao"    # onde o lote é escrito antes de ser publicado
PASTA_CHECKPOINT = PASTA_STREAMING / "checkpoint"    # progresso das consultas
for pasta in (PASTA_ENTRADA, PASTA_PUBLICACAO, PASTA_CHECKPOINT):
    shutil.rmtree(pasta, ignore_errors=True)
    pasta.mkdir(parents=True)

print("Arquivos na entrada:", sorted(p.name for p in PASTA_ENTRADA.iterdir()))
```

```
Arquivos na entrada: []
```

```
# Faixas que alimentam os eventos
COLUNAS_FONTE = {"id_faixa": "id_faixa", "genero": "genero", "artista": "artista",
                 "duracao_s": "duracao_s", "rank": "rank"}

if "df_preparado" not in globals():
    arquivo_preparado = PASTA_PREPARADOS / "faixas_preparadas.csv"
    if arquivo_preparado.exists():
        df_preparado = pd.read_csv(arquivo_preparado)
if "df_preparado" in globals():
    faixas_fonte = (
        df_preparado[df_preparado["tipo_chart"] == "genero"]
        .rename(columns={v: k for k, v in COLUNAS_FONTE.items()})[list(COLUNAS_FONTE)]
    )
    origem_faixas = "conjunto preparado do RA1, charts de gênero"
elif "df_bruto" in globals():
    faixas_fonte = (
        df_bruto[df_bruto["chart_id_genero"] != 0]
        .rename(columns={"id": "id_faixa", "chart_nome_genero": "genero", "artist_name": "artista",
                         "duration": "duracao_s"})[list(COLUNAS_FONTE)]
    )
    origem_faixas = "df_bruto, charts de gênero (fonte provisória)"
else:
    raise FileNotFoundError(
```

```
        "Conjunto preparado não encontrado (df_preparado ou dados/preparados/faixas_preparadas.csv). "
        "Execute as seções do RA1 antes da seção 9."
    )
faixas_fonte = faixas_fonte.dropna().reset_index(drop=True)

print(f"Origem: {origem_faixas}")
print(f"{len(faixas_fonte)} pares faixa-gênero · {faixas_fonte['id_faixa'].nunique()} faixas · "
      f"{faixas_fonte['genero'].nunique()} gêneros · {faixas_fonte['artista'].nunique()} artistas")
```

```
Origem: conjunto preparado do RA1, charts de gênero
2700 pares faixa-gênero · 2578 faixas · 27 gêneros · 1686 artistas
```

```
# Esquema do evento de reprodução
esquema_eventos = StructType([
    StructField("id_evento", IntegerType()),        # sequencial, único na simulação
    StructField("id_faixa", LongType()),            # id da Deezer (passa do limite de um int)
    StructField("genero", StringType()),
    StructField("artista", StringType()),
    StructField("duracao_ouvida_s", IntegerType()), # segundos ouvidos, até a duração da faixa
    StructField("instante", TimestampType()),
])
FORMATO_INSTANTE = "%Y-%m-%d %H:%M:%S"   # o mesmo de timestampFormat na leitura
```

```
# Gerador de eventos
SEMENTE = 42
INICIO_SIMULACAO = datetime(2026, 10, 21, 10, 0)

sorteio = np.random.default_rng(SEMENTE)
proximo_id_evento = 1


def gerar_eventos(n, inicio):
    """Sorteia n reproduções das faixas de faixas_fonte, com instantes crescentes a partir de inicio.

    A chance de cada faixa segue o rank da Deezer (faixa mais popular, mais tocada). Entre um evento e o
    seguinte passam de 5 a 30 segundos; a duração ouvida vai de 30 segundos até a faixa inteira.
    """
    global proximo_id_evento
    pesos = faixas_fonte["rank"] / faixas_fonte["rank"].sum()
    escolhidas = faixas_fonte.iloc[sorteio.choice(len(faixas_fonte), size=n, p=pesos)]
    intervalos = np.cumsum(sorteio.integers(5, 31, size=n))
    lote = []
    for (_, faixa), segundos in zip(escolhidas.iterrows(), intervalos):
        duracao = int(faixa["duracao_s"])
        lote.append({
            "id_evento": proximo_id_evento,
            "id_faixa": int(faixa["id_faixa"]),
            "genero": faixa["genero"],
            "artista": faixa["artista"],
            "duracao_ouvida_s": int(sorteio.integers(min(30, duracao), duracao + 1)),
            "instante": (inicio + timedelta(seconds=int(segundos))).strftime(FORMATO_INSTANTE),
        })
        proximo_id_evento += 1
    return lote
```

```
# Publicação de um lote
lotes_publicados = 0


def publicar_lote(eventos):
    """Grava o lote em JSON (uma linha por evento) em PASTA_PUBLICACAO e move para PASTA_ENTRADA.

    O arquivo só aparece na entrada depois de escrito e fechado, então o Spark nunca lê um lote pela metade.
    """
    global lotes_publicados
    lotes_publicados += 1
    nome = f"lote_{lotes_publicados:03d}.json"
    arquivo = PASTA_PUBLICACAO / nome
    with arquivo.open("w", encoding="utf-8") as saida:
        for evento in eventos:
            saida.write(json.dumps(evento, ensure_ascii=False) + "\n")
    arquivo.replace(PASTA_ENTRADA / nome)
    print(f"Lote {lotes_publicados} publicado: {nome}, {len(eventos)} eventos, "
```

```
        f"de {eventos[0]['instante']} a {eventos[-1]['instante']}")
    return PASTA_ENTRADA / nome
```

```
# Leitura em streaming
eventos = (
    spark.readStream
    .schema(esquema_eventos)
    .option("timestampFormat", "yyyy-MM-dd HH:mm:ss")
    .json(str(PASTA_ENTRADA))
)
print("É um DataFrame em streaming?", eventos.isStreaming)
eventos.printSchema()
```

```
É um DataFrame em streaming? True
root
 |-- id_evento: integer (nullable = true)
 |-- id_faixa: long (nullable = true)
 |-- genero: string (nullable = true)
 |-- artista: string (nullable = true)
 |-- duracao_ouvida_s: integer (nullable = true)
 |-- instante: timestamp (nullable = true)
```

```
# Consulta de recebimento
TABELA_RECEBIMENTO = "recebimento_" + uuid4().hex
recebimento = (
    eventos.agg(
        F.count("*").alias("eventos_recebidos"),
        F.min("instante").alias("primeiro_instante"),
        F.max("instante").alias("ultimo_instante"),
    )
    .writeStream.format("memory")
    .queryName(TABELA_RECEBIMENTO)
    .outputMode("complete")
    .option("checkpointLocation", str(PASTA_CHECKPOINT / "recebimento"))
    .start()
)
print("Consulta ativa?", recebimento.isActive)
print("Arquivos na entrada:", sorted(p.name for p in PASTA_ENTRADA.iterdir()))
spark.table(TABELA_RECEBIMENTO).show(truncate=False)
```

```
Consulta ativa? True
Arquivos na entrada: []
+-----------------+-----------------+---------------+
|eventos_recebidos|primeiro_instante|ultimo_instante|
+-----------------+-----------------+---------------+
+-----------------+-----------------+---------------+
```

```
# 1º lote
primeiro_lote = gerar_eventos(30, INICIO_SIMULACAO)
publicar_lote(primeiro_lote)
display(pd.DataFrame(primeiro_lote).head(10))
```

```
Lote 1 publicado: lote_001.json, 30 eventos, de 2026-10-21 10:00:28 a 2026-10-21 10:09:05
```

	id_evento	id_faixa	genero	artista	duracao_ouvida_s	instante
0	1	4250206701	Asian Music	JISOO	86	2026-10-21 10:00:28
1	2	1457033832	Folk	Aoife O'Donovan	177	2026-10-21 10:00:52
2	3	96774994	Brazilian Music	Rico Dalasam	167	2026-10-21 10:01:06
3	4	722093222	Metal	TOOL	139	2026-10-21 10:01:36
4	5	73707710	Rap/Hip Hop	DJ Snake	195	2026-10-21 10:01:51
5	6	2638201552	Latin Music	FloyyMenor	85	2026-10-21 10:02:04
6	7	4275874622	African Music	FOLA	68	2026-10-21 10:02:32
7	8	3614444782	Asian Music	LE SSERAFIM	127	2026-10-21 10:02:46
8	9	2350185445	Reggaeton	Quevedo	129	2026-10-21 10:02:52

	id_evento	id_faixa	genero	artista	duracao_ouvida_s	instante
9	10	3776492922	Reggae	Nightmares On Wax	61	2026-10-21 10:03:09

```
# Recebimento do 1º lote
recebimento.processAllAvailable()
spark.table(TABELA_RECEBIMENTO).show(truncate=False)
print("Eventos por gênero no 1º lote:")
display(pd.DataFrame(primeiro_lote)["genero"].value_counts().rename("eventos").to_frame())
```

```
+-----------------+------------------+------------------+
|eventos_recebidos|primeiro_instante  |ultimo_instante    |
+-----------------+------------------+------------------+
|30               |2026-10-21 10:00:28|2026-10-21 10:09:05|
+-----------------+------------------+------------------+

Eventos por gênero no 1º lote:
```

genero	eventos
Asian Music	3
Folk	2
Metal	2
Reggae	2
Latin Music	2
African Music	2
Reggaeton	2
Blues	2
Pop	2
Films/Games	2
Brazilian Music	1
Kids	1
Christian	1
Rap/Hip Hop	1
Dance	1
Salsa	1
Alternative	1
Cumbia	1
Rock	1

```
# Encerramento da consulta de recebimento
recebimento.stop()
spark.catalog.dropTempView(TABELA_RECEBIMENTO)
print("Consulta de recebimento ativa?", recebimento.isActive)
```

```
Consulta de recebimento ativa? False
```

10. Aplicação de janelas temporais

- Utilize uma janela **Tumbling** (intervalos sem sobreposição) ou **Sliding** (intervalos que podem se sobrepor).
- Informe o tipo e a duração da janela e o deslocamento, quando aplicável.
- Implemente uma agregação coerente com a análise, como contagem, soma ou média.
- Explique brevemente o que será calculado em cada intervalo.

O foco é demonstrar a compreensão do conceito; não é necessário justificar tecnicamente a duração escolhida.

Resposta do grupo:

Usamos uma única janela **tumbling de 5 minutos**, sem sobreposição. Cada intervalo inclui seu início e exclui seu fim: um evento às 10:05:00 entra em 10:05–10:10, e não em 10:00–10:05. O deslocamento é igual à duração (5 minutos), implícito nesse tipo de janela.

Contamos as reproduções por `genero` usando o instante do evento (`instante`), conforme o objetivo da seção 8. A tabela mostra a contagem de cada gênero em cada intervalo e permite identificar os gêneros com maior contagem, inclusive empates. As contagens representam eventos simulados, não audiência real da Deezer. O modo `complete` reexibe toda a tabela a cada lote; a saída `memory` permite mostrar os resultados na célula e no PDF.

```
# Agregação por gênero em janela tumbling de cinco minutos
from uuid import uuid4
from pyspark.sql import functions as F

if not eventos.isStreaming:
    raise ValueError("Execute a seção 9: eventos deve ser um DataFrame em streaming.")
# Interrompe consultas remanescentes antes de iniciar a consulta desta seção.
for consulta_anterior in spark.streams.active:
    consulta_anterior.stop()

agregado_janelas = eventos.groupBy(
    F.window("instante", "5 minutes"), "genero"
).agg(F.count("*").alias("reproducoes"))
```

```
# Consulta em memória com estado das janelas
# Nome único para poder rodar a seção novamente.
# O checkpoint é a pasta onde o Spark guarda o progresso desta consulta.
TABELA_JANELAS = "janelas_" + uuid4().hex
consulta = (
    agregado_janelas.writeStream
    .outputMode("complete")
    .format("memory")
    .queryName(TABELA_JANELAS)
    .option("checkpointLocation", str(PASTA_CHECKPOINT / TABELA_JANELAS))
    .start()
)
print(f"Consulta ativa: {consulta.isActive}; tabela em memória: {TABELA_JANELAS}")
```

```
Consulta ativa: True; tabela em memória: janelas_940bed741f034a579d853456c5358d5b
```

```
# Tabela das janelas após o primeiro lote
consulta.processAllAvailable()
tabela_primeiro_lote = spark.table(TABELA_JANELAS)
quantidade_grupos = tabela_primeiro_lote.count()
# O limite é o número real de grupos, para que show() não esconda linhas além das primeiras 20.
tabela_primeiro_lote.select(
    F.col("window.start").alias("inicio"),
    F.col("window.end").alias("fim"), "genero", "reproducoes"
).orderBy("inicio", F.desc("reproducoes"), "genero").show(n=max(1, quantidade_grupos), truncate=False)

# Somamos as contagens da tabela para conferir quantos eventos foram recebidos.
total_reproducoes = tabela_primeiro_lote.agg(
    F.sum("reproducoes").alias("total")
).first()["total"]
print(f"Total de reproduções recebidas: {total_reproducoes or 0}")
# A consulta permanece ativa para os novos lotes e o encerramento da seção 11.
```

```
+-------------------+-------------------+--------------+-----------+
|inicio             |fim                |genero        |reproducoes|
+-------------------+-------------------+--------------+-----------+
|2026-10-21 10:00:00|2026-10-21 10:05:00|Asian Music   |2          |
|2026-10-21 10:00:00|2026-10-21 10:05:00|Folk          |2          |
|2026-10-21 10:00:00|2026-10-21 10:05:00|African Music |1          |
|2026-10-21 10:00:00|2026-10-21 10:05:00|Blues         |1          |
|2026-10-21 10:00:00|2026-10-21 10:05:00|Brazilian Music|1          |
|2026-10-21 10:00:00|2026-10-21 10:05:00|Christian     |1          |
|2026-10-21 10:00:00|2026-10-21 10:05:00|Dance         |1          |
|2026-10-21 10:00:00|2026-10-21 10:05:00|Films/Games   |1          |
|2026-10-21 10:00:00|2026-10-21 10:05:00|Kids          |1          |
|2026-10-21 10:00:00|2026-10-21 10:05:00|Latin Music   |1          |
```

```
|2026-10-21 10:00:00|2026-10-21 10:05:00|Metal          |1          |
|2026-10-21 10:00:00|2026-10-21 10:05:00|Rap/Hip Hop    |1          |
|2026-10-21 10:00:00|2026-10-21 10:05:00|Reggae         |1          |
|2026-10-21 10:00:00|2026-10-21 10:05:00|Reggaeton      |1          |
|2026-10-21 10:05:00|2026-10-21 10:10:00|Pop            |2          |
|2026-10-21 10:05:00|2026-10-21 10:10:00|African Music  |1          |
|2026-10-21 10:05:00|2026-10-21 10:10:00|Alternative    |1          |
|2026-10-21 10:05:00|2026-10-21 10:10:00|Asian Music    |1          |
|2026-10-21 10:05:00|2026-10-21 10:10:00|Blues          |1          |
|2026-10-21 10:05:00|2026-10-21 10:10:00|Cumbia         |1          |
|2026-10-21 10:05:00|2026-10-21 10:10:00|Films/Games    |1          |
|2026-10-21 10:05:00|2026-10-21 10:10:00|Latin Music    |1          |
|2026-10-21 10:05:00|2026-10-21 10:10:00|Metal          |1          |
|2026-10-21 10:05:00|2026-10-21 10:10:00|Reggae         |1          |
|2026-10-21 10:05:00|2026-10-21 10:10:00|Reggaeton      |1          |
|2026-10-21 10:05:00|2026-10-21 10:10:00|Rock           |1          |
|2026-10-21 10:05:00|2026-10-21 10:10:00|Salsa          |1          |
+-------------------+-------------------+---------------+-----------+

Total de reproduções recebidas: 30
```

11. Resultados e interpretação

Apresente os resultados do processamento e demonstre como a análise se comporta com a chegada de novos registros.

```
# Preparação da comparação entre lotes
from datetime import datetime
from pyspark.sql import functions as F

if not consulta.isActive:
    raise RuntimeError("Execute as seções 9 e 10 antes de demonstrar os novos lotes.")


def ler_resultados_janelas():
    """Espera os arquivos disponíveis e copia o resultado atual para comparação."""
    consulta.processAllAvailable()
    return (
        spark.table(TABELA_JANELAS)
        .select(
            F.col("window.start").alias("inicio"),
            F.col("window.end").alias("fim"),
            "genero", "reproducoes",
        )
        .orderBy("inicio", F.desc("reproducoes"), "genero")
        .toPandas()
    )


resultados_atuais = ler_resultados_janelas()
lotes_demonstrados = [primeiro_lote]


def publicar_proximo_lote(quantidade=30):
    """Publica novas reproduções e mostra o resultado completo e as mudanças por janela."""
    global resultados_atuais
    if not consulta.isActive:
        raise RuntimeError("A consulta foi encerrada. Execute novamente as seções 9 e 10.")
    if not isinstance(quantidade, int) or quantidade <= 0:
        raise ValueError("A quantidade de eventos deve ser um inteiro positivo.")

    anteriores = resultados_atuais
    inicio = datetime.strptime(lotes_demonstrados[-1][-1]["instante"], FORMATO_INSTANTE)
    novo_lote = gerar_eventos(quantidade, inicio)
    publicar_lote(novo_lote)
    atuais = ler_resultados_janelas()

    chaves = ["inicio", "fim", "genero"]
    mudancas = atuais.merge(
        anteriores, on=chaves, how="outer", suffixes=("_depois", "_antes")
    ).fillna({"reproducoes_antes": 0, "reproducoes_depois": 0})
    for coluna in ("reproducoes_antes", "reproducoes_depois"):
        mudancas[coluna] = mudancas[coluna].astype("int64")
    mudancas["novas_reproducoes"] = mudancas["reproducoes_depois"] - mudancas["reproducoes_antes"]
    assert mudancas["novas_reproducoes"].ge(0).all(), "Uma contagem anterior diminuiu."
```

```
    assert int(mudancas["novas_reproducoes"].sum()) == len(novo_lote), "O lote não foi contado integralmente."

    lotes_demonstrados.append(novo_lote)
    total_esperado = sum(len(lote) for lote in lotes_demonstrados)
    total_recebido = int(atuais["reproducoes"].sum())
    assert total_recebido == total_esperado, "Total recebido diferente dos lotes publicados."

    resumo = mudancas.groupby(["inicio", "fim"], as_index=False)[
        ["reproducoes_antes", "novas_reproducoes", "reproducoes_depois"]
    ].sum()
    print(f"Após o lote {len(lotes_demonstrados)}: {total_recebido} reproduções recebidas.")
    with pd.option_context("display.max_rows", None):
        print("Contagens por gênero e janela:")
        display(atuais)
        print("Mudanças por janela (início incluído, fim excluído):")
        display(resumo)
    resultados_atuais = atuais
    return novo_lote
```

```
# Segundo lote: atualização de uma janela existente e abertura de novos intervalos
segundo_lote = publicar_proximo_lote()
resultados_apos_segundo_lote = resultados_atuais.copy()
```

```
Lote 2 publicado: lote_002.json, 30 eventos, de 2026-10-21 10:09:34 a 2026-10-21 10:17:57
Após o lote 2: 60 reproduções recebidas.
Contagens por gênero e janela:
```

	inicio	fim	genero	reproducoes
0	2026-10-21 10:00:00	2026-10-21 10:05:00	Asian Music	2
1	2026-10-21 10:00:00	2026-10-21 10:05:00	Folk	2
2	2026-10-21 10:00:00	2026-10-21 10:05:00	African Music	1
3	2026-10-21 10:00:00	2026-10-21 10:05:00	Blues	1
4	2026-10-21 10:00:00	2026-10-21 10:05:00	Brazilian Music	1
5	2026-10-21 10:00:00	2026-10-21 10:05:00	Christian	1
6	2026-10-21 10:00:00	2026-10-21 10:05:00	Dance	1
7	2026-10-21 10:00:00	2026-10-21 10:05:00	Films/Games	1
8	2026-10-21 10:00:00	2026-10-21 10:05:00	Kids	1
9	2026-10-21 10:00:00	2026-10-21 10:05:00	Latin Music	1
10	2026-10-21 10:00:00	2026-10-21 10:05:00	Metal	1
11	2026-10-21 10:00:00	2026-10-21 10:05:00	Rap/Hip Hop	1
12	2026-10-21 10:00:00	2026-10-21 10:05:00	Reggae	1
13	2026-10-21 10:00:00	2026-10-21 10:05:00	Reggaeton	1
14	2026-10-21 10:05:00	2026-10-21 10:10:00	Metal	2
15	2026-10-21 10:05:00	2026-10-21 10:10:00	Pop	2
16	2026-10-21 10:05:00	2026-10-21 10:10:00	Reggae	2
17	2026-10-21 10:05:00	2026-10-21 10:10:00	African Music	1
18	2026-10-21 10:05:00	2026-10-21 10:10:00	Alternative	1
19	2026-10-21 10:05:00	2026-10-21 10:10:00	Asian Music	1
20	2026-10-21 10:05:00	2026-10-21 10:10:00	Blues	1
21	2026-10-21 10:05:00	2026-10-21 10:10:00	Cumbia	1
22	2026-10-21 10:05:00	2026-10-21 10:10:00	Films/Games	1
23	2026-10-21 10:05:00	2026-10-21 10:10:00	Latin Music	1
24	2026-10-21 10:05:00	2026-10-21 10:10:00	Reggaeton	1
25	2026-10-21 10:05:00	2026-10-21 10:10:00	Rock	1
26	2026-10-21 10:05:00	2026-10-21 10:10:00	Salsa	1
27	2026-10-21 10:05:00	2026-10-21 10:10:00	Traditional Mexicano	1

	inicio	fim	genero	reproducoes
28	2026-10-21 10:10:00	2026-10-21 10:15:00	Dance	2
29	2026-10-21 10:10:00	2026-10-21 10:15:00	Metal	2
30	2026-10-21 10:10:00	2026-10-21 10:15:00	Pop	2
31	2026-10-21 10:10:00	2026-10-21 10:15:00	R&B	2
32	2026-10-21 10:10:00	2026-10-21 10:15:00	Salsa	2
33	2026-10-21 10:10:00	2026-10-21 10:15:00	African Music	1
34	2026-10-21 10:10:00	2026-10-21 10:15:00	Alternative	1
35	2026-10-21 10:10:00	2026-10-21 10:15:00	Asian Music	1
36	2026-10-21 10:10:00	2026-10-21 10:15:00	Brazilian Music	1
37	2026-10-21 10:10:00	2026-10-21 10:15:00	Electro	1
38	2026-10-21 10:10:00	2026-10-21 10:15:00	Films/Games	1
39	2026-10-21 10:10:00	2026-10-21 10:15:00	Folk	1
40	2026-10-21 10:10:00	2026-10-21 10:15:00	Traditional Mexicano	1
41	2026-10-21 10:15:00	2026-10-21 10:20:00	Rock	2
42	2026-10-21 10:15:00	2026-10-21 10:20:00	Asian Music	1
43	2026-10-21 10:15:00	2026-10-21 10:20:00	Country	1
44	2026-10-21 10:15:00	2026-10-21 10:20:00	Electro	1
45	2026-10-21 10:15:00	2026-10-21 10:20:00	Pop	1
46	2026-10-21 10:15:00	2026-10-21 10:20:00	Rap/Hip Hop	1
47	2026-10-21 10:15:00	2026-10-21 10:20:00	Reggae	1
48	2026-10-21 10:15:00	2026-10-21 10:20:00	Soul & Funk	1

Mudanças por janela (início incluído, fim excluído):

	inicio	fim	reproducoes_antes	novas_reproducoes	reproducoes_depois
0	2026-10-21 10:00:00	2026-10-21 10:05:00	16	0	16
1	2026-10-21 10:05:00	2026-10-21 10:10:00	14	3	17
2	2026-10-21 10:10:00	2026-10-21 10:15:00	0	18	18
3	2026-10-21 10:15:00	2026-10-21 10:20:00	0	9	9

```
# Terceiro lote: novas reproduções e comparação das contagens acumuladas
terceiro_lote = publicar_proximo_lote()
resultados_apos_terceiro_lote = resultados_atuais.copy()
```

```
Lote 3 publicado: lote_003.json, 30 eventos, de 2026-10-21 10:18:11 a 2026-10-21 10:26:15
Após o lote 3: 90 reproduções recebidas.
Contagens por gênero e janela:
```

	inicio	fim	genero	reproducoes
0	2026-10-21 10:00:00	2026-10-21 10:05:00	Asian Music	2
1	2026-10-21 10:00:00	2026-10-21 10:05:00	Folk	2
2	2026-10-21 10:00:00	2026-10-21 10:05:00	African Music	1
3	2026-10-21 10:00:00	2026-10-21 10:05:00	Blues	1
4	2026-10-21 10:00:00	2026-10-21 10:05:00	Brazilian Music	1
5	2026-10-21 10:00:00	2026-10-21 10:05:00	Christian	1
6	2026-10-21 10:00:00	2026-10-21 10:05:00	Dance	1
7	2026-10-21 10:00:00	2026-10-21 10:05:00	Films/Games	1
8	2026-10-21 10:00:00	2026-10-21 10:05:00	Kids	1
9	2026-10-21 10:00:00	2026-10-21 10:05:00	Latin Music	1

	inicio	fim	genero	reproducoes
10	2026-10-21 10:00:00	2026-10-21 10:05:00	Metal	1
11	2026-10-21 10:00:00	2026-10-21 10:05:00	Rap/Hip Hop	1
12	2026-10-21 10:00:00	2026-10-21 10:05:00	Reggae	1
13	2026-10-21 10:00:00	2026-10-21 10:05:00	Reggaeton	1
14	2026-10-21 10:05:00	2026-10-21 10:10:00	Metal	2
15	2026-10-21 10:05:00	2026-10-21 10:10:00	Pop	2
16	2026-10-21 10:05:00	2026-10-21 10:10:00	Reggae	2
17	2026-10-21 10:05:00	2026-10-21 10:10:00	African Music	1
18	2026-10-21 10:05:00	2026-10-21 10:10:00	Alternative	1
19	2026-10-21 10:05:00	2026-10-21 10:10:00	Asian Music	1
20	2026-10-21 10:05:00	2026-10-21 10:10:00	Blues	1
21	2026-10-21 10:05:00	2026-10-21 10:10:00	Cumbia	1
22	2026-10-21 10:05:00	2026-10-21 10:10:00	Films/Games	1
23	2026-10-21 10:05:00	2026-10-21 10:10:00	Latin Music	1
24	2026-10-21 10:05:00	2026-10-21 10:10:00	Reggaeton	1
25	2026-10-21 10:05:00	2026-10-21 10:10:00	Rock	1
26	2026-10-21 10:05:00	2026-10-21 10:10:00	Salsa	1
27	2026-10-21 10:05:00	2026-10-21 10:10:00	Traditional Mexicano	1
28	2026-10-21 10:10:00	2026-10-21 10:15:00	Dance	2
29	2026-10-21 10:10:00	2026-10-21 10:15:00	Metal	2
30	2026-10-21 10:10:00	2026-10-21 10:15:00	Pop	2
31	2026-10-21 10:10:00	2026-10-21 10:15:00	R&B	2
32	2026-10-21 10:10:00	2026-10-21 10:15:00	Salsa	2
33	2026-10-21 10:10:00	2026-10-21 10:15:00	African Music	1
34	2026-10-21 10:10:00	2026-10-21 10:15:00	Alternative	1
35	2026-10-21 10:10:00	2026-10-21 10:15:00	Asian Music	1
36	2026-10-21 10:10:00	2026-10-21 10:15:00	Brazilian Music	1
37	2026-10-21 10:10:00	2026-10-21 10:15:00	Electro	1
38	2026-10-21 10:10:00	2026-10-21 10:15:00	Films/Games	1
39	2026-10-21 10:10:00	2026-10-21 10:15:00	Folk	1
40	2026-10-21 10:10:00	2026-10-21 10:15:00	Traditional Mexicano	1
41	2026-10-21 10:15:00	2026-10-21 10:20:00	Country	2
42	2026-10-21 10:15:00	2026-10-21 10:20:00	Electro	2
43	2026-10-21 10:15:00	2026-10-21 10:20:00	Pop	2
44	2026-10-21 10:15:00	2026-10-21 10:20:00	Rap/Hip Hop	2
45	2026-10-21 10:15:00	2026-10-21 10:20:00	Rock	2
46	2026-10-21 10:15:00	2026-10-21 10:20:00	Alternative	1
47	2026-10-21 10:15:00	2026-10-21 10:20:00	Asian Music	1
48	2026-10-21 10:15:00	2026-10-21 10:20:00	Films/Games	1
49	2026-10-21 10:15:00	2026-10-21 10:20:00	Reggae	1
50	2026-10-21 10:15:00	2026-10-21 10:20:00	Soul & Funk	1
51	2026-10-21 10:15:00	2026-10-21 10:20:00	Traditional Mexicano	1
52	2026-10-21 10:20:00	2026-10-21 10:25:00	Traditional Mexicano	4
53	2026-10-21 10:20:00	2026-10-21 10:25:00	Country	3

	inicio	fim	genero	reproducoes
54	2026-10-21 10:20:00	2026-10-21 10:25:00	Kids	2
55	2026-10-21 10:20:00	2026-10-21 10:25:00	Rap/Hip Hop	2
56	2026-10-21 10:20:00	2026-10-21 10:25:00	Alternative	1
57	2026-10-21 10:20:00	2026-10-21 10:25:00	Asian Music	1
58	2026-10-21 10:20:00	2026-10-21 10:25:00	Latin Music	1
59	2026-10-21 10:20:00	2026-10-21 10:25:00	Pop	1
60	2026-10-21 10:20:00	2026-10-21 10:25:00	Reggaeton	1
61	2026-10-21 10:20:00	2026-10-21 10:25:00	Rock	1
62	2026-10-21 10:25:00	2026-10-21 10:30:00	Alternative	1
63	2026-10-21 10:25:00	2026-10-21 10:30:00	Country	1
64	2026-10-21 10:25:00	2026-10-21 10:30:00	Folk	1
65	2026-10-21 10:25:00	2026-10-21 10:30:00	Jazz	1
66	2026-10-21 10:25:00	2026-10-21 10:30:00	Pop	1
67	2026-10-21 10:25:00	2026-10-21 10:30:00	R&B	1

Mudanças por janela (início incluído, fim excluído):

	inicio	fim	reproducoes_antes	novas_reproducoes	reproducoes_depois
0	2026-10-21 10:00:00	2026-10-21 10:05:00	16	0	16
1	2026-10-21 10:05:00	2026-10-21 10:10:00	17	0	17
2	2026-10-21 10:10:00	2026-10-21 10:15:00	18	0	18
3	2026-10-21 10:15:00	2026-10-21 10:20:00	9	7	16
4	2026-10-21 10:20:00	2026-10-21 10:25:00	0	17	17
5	2026-10-21 10:25:00	2026-10-21 10:30:00	0	6	6

```
# Encerramento da consulta e limpeza das subpastas da simulação
# Demonstração ao vivo: antes de executar esta célula, execute publicar_proximo_lote(10) em uma
# célula de código para publicar mais dez eventos e mostrar as mudanças. A função continua a
# sequência de IDs e instantes do lote anterior. Para repetir a demonstração desde o começo,
# execute novamente as seções 9, 10 e 11.
import shutil

consulta.stop()
spark.catalog.dropTempView(TABELA_JANELAS)
for pasta in (PASTA_ENTRADA, PASTA_PUBLICACAO, PASTA_CHECKPOINT):
    destino = pasta.resolve()
    if destino.parent != (RAIZ / "dados" / "streaming").resolve():
        raise ValueError(f"Pasta fora do diretório da simulação: {destino}")
    if destino.exists():
        shutil.rmtree(destino)
print("Consulta ativa após o encerramento?", consulta.isActive)
print("Subpastas de entrada, publicação e checkpoint removidas.")
```

```
Consulta ativa após o encerramento? False
Subpastas de entrada, publicação e checkpoint removidas.
```

Resposta do grupo:

As células “Segundo lote: atualização de uma janela existente e abertura de novos intervalos” e “Terceiro lote: novas reproduções e comparação das contagens acumuladas” publicam mais 30 eventos cada, em momentos distintos, e mostram a tabela após o processamento. Com os 30 eventos do primeiro lote, o total recebido passa de 30 para 60 e depois para 90.

O segundo lote acrescenta 3 reproduções em 10:05–10:10 (de 14 para 17), 18 em 10:10–10:15 e 9 em 10:15–10:20. O terceiro acrescenta 7 em 10:15–10:20 (de 9 para 16), 17 em 10:20–10:25 e 6 em 10:25–10:30. A janela 10:00–10:05 mantém suas 16 reproduções, pois nenhum evento dos dois novos lotes pertence a esse intervalo. Essas contagens são apresentadas nos resumos “Mudanças por janela” das duas células.

As janelas são atribuídas pelo instante de cada evento, não pelo horário em que o arquivo foi publicado. Assim, uma janela já exibida recebe novas contagens quando chegam eventos cujo instante ainda pertence a ela. A tabela por gênero permite comparar quais gêneros concentram as reproduções em cada intervalo; os valores representam uma simulação com semente fixa, e não a audiência real da Deezer.

12. Considerações do RA2

Responda brevemente:

- O que foi possível observar com o processamento em streaming?
- Qual foi a contribuição das janelas temporais para a análise?
- Essa abordagem faria sentido em uma aplicação real do projeto? Por quê?

Na última resposta, o grupo pode reconhecer que o streaming foi utilizado apenas como exercício didático, se esse for o caso.

Resposta do grupo:

O que observamos com o streaming. A consulta processou cada lote assim que ele chegou à pasta monitorada, sem reler os anteriores: o total recebido passou de 30 para 60 e depois para 90 reproduções, e a tabela mudou a cada lote (seção 11, células "Segundo lote: atualização de uma janela existente e abertura de novos intervalos" e "Terceiro lote: novas reproduções e comparação das contagens acumuladas"). Um lote novo pode atualizar uma janela já exibida, como 10:05–10:10, que foi de 14 para 17, e abrir janelas novas, como 10:20–10:25, com 17. A janela 10:00–10:05 ficou em 16, porque nenhum evento novo caiu nela.

Contribuição das janelas temporais. A janela tumbling de 5 minutos transformou um fluxo contínuo de eventos em intervalos comparáveis: em vez de um total único, cada intervalo mostra quantas reproduções cada gênero teve (seção 10). Como a janela usa o instante do evento, e não a hora de chegada do arquivo, um evento atrasado ainda é contado no intervalo certo. É isso que permite responder ao objetivo da seção 8: qual gênero concentra mais reproduções em cada intervalo.

Uso numa aplicação real. Faria sentido com eventos reais de reprodução, por exemplo para a Deezer ou uma gravadora perceberem em minutos um gênero ou uma faixa ganhando audiência. Neste projeto, porém, o streaming foi um exercício didático: a API pública só oferece um retrato diário dos charts, sem fluxo de reproduções, e os eventos são simulados a partir do conjunto preparado do RA1, com semente fixa. Os números mostram o funcionamento do processamento, não a audiência real.